

# Løsningsforslag Unik4590/9590/TTK4205 - 2016H

16. desember 2017

## Oppgave 1

### Innledning

- a) Se f.eks. figur 8 i forelesningsnotatene, og den tilhørende figurteksten.
- b) Se f.eks. figur 3 i forelesningsnotatene.
- c) Se avsnitt 1.2 i forelesningsnotatene og eksempelet på beslutningsregel midt på side 7.
- d) Mulig svar: Ledet læring består i å trene opp en klassifikator ved hjelp av objekter (egenskapsvektorer) med *kjent* klassetilhørighet. Treningen kan utføres ved bl.a. parametriske- eller ikke-parametriske metoder for estimering av sannsynlighetstetthetsfunksjoner, eller optimalisering av kriteriefunksjoner for å finne vektene i diskriminantfunksjoner direkte fra treningssamplene.

## Oppgave 2

### Bayesisk beslutningsteori

- a) Se avsnitt 2.1 i forelesningsnotatene.
- b) Se avsnitt 2.3 i forelesningsnotatene.
- c) Desisjongsgrensen (terskelverdien) er i dette tilfellet gitt ved den verdien av  $x$  som tilfredsstiller likningen

$$P(\omega_1|x) = P(\omega_2|x),$$

som ved innsetting i Bayes regel og fjerning av den felles nevneren  $p(x)$  gir

$$p(x|\omega_1)P(\omega_1) = p(x|\omega_2)P(\omega_2).$$

Innsetting av den univariate normalfordelingen gir da

$$\frac{1}{\sqrt{2\pi}\sigma_i} \exp \left[ -\frac{1}{2} \left( \frac{x - \mu_i}{\sigma_i} \right)^2 \right] P(\omega_1) = \frac{1}{\sqrt{2\pi}\sigma_i} \exp \left[ -\frac{1}{2} \left( \frac{x - \mu_i}{\sigma_i} \right)^2 \right] P(\omega_2),$$

som med innsetting av  $\sigma_1 = \sigma_2 = \sigma$  og bruk av den naturlige logaritmen på begge sider av likhetstegnet gir

$$-\frac{1}{2} \left( \frac{x - \mu_1}{\sigma} \right)^2 + \ln P(\omega_1) = -\frac{1}{2} \left( \frac{x - \mu_2}{\sigma} \right)^2 + \ln P(\omega_2)$$

og derav

$$-x^2 + 2\mu_1 x - \mu_1^2 + 2\sigma^2 \ln P(\omega_1) = -x^2 + 2\mu_2 x - \mu_2^2 + 2\sigma^2 \ln P(\omega_2)$$

som kan forenkles til

$$2(\mu_1 - \mu_2)x + (\mu_2 - \mu_1)(\mu_2 + \mu_1) + 2\sigma^2 \ln \frac{P(\omega_1)}{P(\omega_2)} = 0.$$


Desisjongsgrensen er derved gitt ved

$$x_0 = \frac{(\mu_1 - \mu_2)(\mu_1 + \mu_2) - 2\sigma^2 \ln \frac{P(\omega_1)}{P(\omega_2)}}{2(\mu_1 - \mu_2)} = \frac{1}{2}(\mu_1 + \mu_2) - \frac{\sigma^2}{(\mu_1 - \mu_2)} \ln \frac{P(\omega_1)}{P(\omega_2)}.$$

d) Med like a priori sannsynligheter blir terskelverdien

$$x_0 = \frac{1}{2}(\mu_1 + \mu_2),$$

siden  $\ln(P(\omega_1)/P(\omega_2)) = 0$  i dette tilfellet. Figuren viser terskelen og feilraten (skravert areal).



e) Med  $P(\omega_1) = 1/4$  og  $P(\omega_2) = 3/4$  blir terskelverdien

$$x_0 = \frac{1}{2}(\mu_1 + \mu_2) - \frac{\sigma^2}{\mu_1 - \mu_2} \ln \left( \frac{1/4}{3/4} \right) = \frac{1}{2}(\mu_1 + \mu_2) + \frac{\sigma^2}{\mu_1 - \mu_2} \ln(3).$$

### Oppg. 3

Diskriminantfunksjoner

a) Se avsnitt 2.5 i forelesningsnotatene.

b) Med fordelingen

$$p(\mathbf{x}|\omega_i) = \frac{1}{(2\pi)^{d/2}|\Sigma_i|^{1/2}} \exp \left[ -\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu}_i)^t \Sigma_i^{-1} (\mathbf{x} - \boldsymbol{\mu}_i) \right]$$

kan man sette opp diskriminantfunksjoner på formen

$$g_i(\mathbf{x}) = \ln p(\mathbf{x}|\omega_i) + \ln P(\omega_i),$$

som ved innsetting for tetthetsfunksjonen gir

$$\begin{aligned} g_i(\mathbf{x}) &= -\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu}_i)^t \Sigma_i^{-1} (\mathbf{x} - \boldsymbol{\mu}_i) - \frac{d}{2} \ln 2\pi - \frac{1}{2} \ln |\Sigma_i| + \ln P(\omega_i) \\ &= -\frac{1}{2} \mathbf{x}^t \Sigma_i^{-1} \mathbf{x} + \mathbf{x}^t \Sigma_i^{-1} \boldsymbol{\mu}_i - \frac{1}{2} \boldsymbol{\mu}_i^t \Sigma_i^{-1} \boldsymbol{\mu}_i - \frac{d}{2} \ln 2\pi - \frac{1}{2} \ln |\Sigma_i| + \ln P(\omega_i), \end{aligned}$$

og siden kovariansmatriser og apriorisannsynligheter er like for alle klasser

$$= -\frac{1}{2} \mathbf{x}^t \Sigma^{-1} \mathbf{x} + \mathbf{x}^t \Sigma^{-1} \boldsymbol{\mu}_i - \frac{1}{2} \boldsymbol{\mu}_i^t \Sigma^{-1} \boldsymbol{\mu}_i - \frac{d}{2} \ln 2\pi - \frac{1}{2} \ln |\Sigma| + \ln \frac{1}{3}.$$

Her kan ledd som er felles for alle klasser strykes, slik at diskriminantfunksjonene blir

$$g_i(\mathbf{x}) = \mathbf{w}_i^t \mathbf{x} + w_{i0},$$

der

$$\mathbf{w}_i = \Sigma^{-1} \boldsymbol{\mu}_i$$

og

$$w_{i0} = -\frac{1}{2} \boldsymbol{\mu}_i^t \Sigma^{-1} \boldsymbol{\mu}_i$$

for hver klasse  $\omega_i$ ,  $i = 1, 2, 3$ . Her er kovariansmatrisen for alle klasser, gitt ved

$$\Sigma = \begin{bmatrix} 4 & 1 \\ 1 & 3 \end{bmatrix},$$

og den inverse, som kan finnes ved å løse et likningssystem, blir

$$\Sigma^{-1} = \frac{1}{8} \begin{bmatrix} 3 & -2 \\ -2 & 4 \end{bmatrix}.$$

Innsetting av  $\Sigma^{-1}$  og forventningsvektorene

$$\boldsymbol{\mu}_1 = \begin{bmatrix} 1 \\ 3 \end{bmatrix}, \quad \boldsymbol{\mu}_2 = \begin{bmatrix} 3 \\ 6 \end{bmatrix} \quad \text{og} \quad \boldsymbol{\mu}_3 = \begin{bmatrix} 4 \\ 1 \end{bmatrix}$$

i uttrykket for diskriminantfunksjonen ovenfor, gir da

$$g_1(\mathbf{x}) = 2[-3, 10]\mathbf{x} - 27$$

$$g_2(\mathbf{x}) = 2[-3, 18]\mathbf{x} - 99$$

$$g_3(\mathbf{x}) = 2[10, -4]\mathbf{x} - 36.$$

c) Diskriminantfunksjonene er lineære, siden  $\mathbf{x}$  bare inngår til første orden. Desisjongrensene vil da bestå av hyperplan (rette linjestykker i dette tilfellet, siden  $d = 2$ ). Siden lineære diskriminantfunksjoner gir opphav til like mange (enkeltsammenhengende) regioner som antall klasser, er svaret her *tre* regioner.

d) Ved å sette inn det ukjente objektet representert ved egenskapsvektoren

$$\mathbf{x}_0 = \begin{bmatrix} 2 \\ 2 \end{bmatrix}$$

i diskriminantfunksjonene ovenfor, får man

$$g_1(\mathbf{x}_0) = 2[-3, 10] \begin{bmatrix} 2 \\ 2 \end{bmatrix} - 27 = 1$$

$$g_2(\mathbf{x}_0) = 2[-3, 18] \begin{bmatrix} 2 \\ 2 \end{bmatrix} - 99 = -39$$

$$g_3(\mathbf{x}_0) = 2[10, -4] \begin{bmatrix} 2 \\ 2 \end{bmatrix} - 36 = -12.$$

Siden  $g_1$  har størst verdi, blir objektet klassifisert til  $\omega_1$ .

## Oppg. 4

Parametriske metoder

a) Se avsnitt 3.1 i forelesningsnotatene (side 34).

b) For Maxwellfordelingen

$$p(x|\theta) = \begin{cases} \frac{4}{\sqrt{\pi}} \theta^{3/2} x^2 e^{-\theta x^2} & x \geq 0 \\ 0 & \text{ellers,} \end{cases}$$

der  $\theta > 0$ , blir log-likelihoodfunksjonen

$$\begin{aligned} \mathcal{L}(\theta) &= \sum_{k=1}^n \ln p(x_k|\theta) \\ &= \sum_{k=1}^n \ln \left( \frac{4}{\sqrt{\pi}} \theta^{3/2} x_k^2 e^{-\theta x_k^2} \right) \\ &= \sum_{k=1}^n \left( \ln \frac{4}{\sqrt{\pi}} x_k^2 + \frac{3}{2} \ln \theta - \theta x_k^2 \right). \end{aligned}$$

Gradienten til log-likelihoodfunksjonen m.h.p.  $\theta$  (i dette tilfellet den deriverte) blir da

$$\begin{aligned}\frac{d\mathcal{L}(\theta)}{d\theta} &= \sum_{k=1}^n \frac{d}{d\theta} \left( \ln \frac{4}{\sqrt{\pi}} x_k^2 + \frac{3}{2} \ln \theta - \theta x_k^2 \right) \\ &= \sum_{k=1}^n \left( \frac{3}{2\theta} - x_k^2 \right) = \frac{3n}{2\theta} - \sum_{k=1}^n x_k^2.\end{aligned}$$

Ved å sette den deriverte lik null, blir løsningen for parameterestimatet

$$\hat{\theta} = \frac{3n}{2 \sum_{k=1}^n x_k^2}.$$

c) Forslag til svar: Bayesisk estimering skiller seg fra maksimum likelihood estimering ved at man her betrakter parametervektoren i problemet som en stokastisk variabel. Dette gir mulighet til å inkorporere apriori kunnskap i parameterestimeringen gjennom en apriori parameterfordeling  $p(\boldsymbol{\theta})$ . Ved å introdusere treningssamplene, blir apriorifordelingen konvertert til en a posteriori parameterfordeling  $p(\boldsymbol{\theta}|\mathcal{X})$ , som normalt vil konvergere mot Diracs deltafunksjon omkring maksimum likelihoodløsningen når  $n \rightarrow \infty$ . For endelig  $n$  vil parameterestimatet typisk være et vektet middel av aprioriinformasjon og informasjon fra samplene i treningssettet.

## Oppg. 5

Ikke-parametriske metoder

a) Se avsnitt 4.1 i forelesningsnotatene, først og fremst formelen for  $p_n(\mathbf{x})$  og konvergensbetingelsene på side 50.

c) Se avsnitt 4.2.2 og resultatet i 4.2.3 (side 61).

d) Forslag: Ikke-parametriske metoder krever ingen antakelse om formen på fordelingene, men er på den annen side mer tidkrevende å bruke for klassifisering, og krever også at hele treningssettet lagres som del av klassifikatoren. Det kan også nevnes at nærmeste-nabo metodene (k-NNR og NNR) har en øvre grense for den asymptotiske feilraten, og er derfor godt egnet til å prøve ut ulike egenskapskombinasjoner, fordi man da har mulighet til å sammenlikne feilraten med hva som er optimalt oppnåelig.