

Løsningsforslag eksamen TEK5020 - 2020H

Oppgave 1

Innledning

- a) Her kan det lages en skisse i likhet med figur 3 i forelesningsnotatene, som beskriver sensor (kamera), egenskapsuttrekker og klassifikator, med litt forklaring av disse begrepene (se side 7 i forelesningsnotatene).
- b) Et treningssett er en samling av egenskapsvektorer fra klassene som inngår i problemet. Vanligvis er klassetilhørigheten til samplene i treningssettet kjent (ledet læring, se avsnitt 1.3 i forelesningsnotatene), men den kan også være ukjent (ikke-ledet læring). Som eksempler på metoder kan nevnes parametriske metoder, ikke-parametriske metoder og trening av lineære diskriminantfunksjoner, med kort forklaring av prinsippene.
- c) Kort forklaring, som i avsnitt 2.5 i forelesningsnotatene (side 19-20), med et par eksempler på mulige diskriminantfunksjoner (side 20).
- d) Bruk av et uavhengig testsett er viktig for å få et realistisk estimat av ytelsen til en klassifikator. Dette gjør det mulig å avdekke eventuell overtrening av klassifikatoren (spesialisering til treningssettet) og ellers forsikre seg om at klassifikatoren kan generalisere til nye data. Mulige fremgangsmåter er beskrevet i avsnitt 6.1.2 i forelesningsnotatene.

Oppgave 2

Beslutningsteori

- a) Se avsnitt 1.4.1 og 2.1 (til og med Bayes regel) i forelesningsnotatene.
- b) Se avsnitt 2.1 i forelesningsnotatene.
- c) Betinget risk (forventet tap) er kostnaden forbundet ved en gitt handling, gitt en måling (dvs. egenskapsvektoren \mathbf{x} for et ukjent objekt):

$$R(\alpha_i|\mathbf{x}) = \sum_{j=1}^c \lambda(\alpha_i|\omega_j)P(\omega_j|\mathbf{x}), i=1,\dots,a.$$

Total risk er gitt ved

$$R = \int_{\mathbb{R}^d} R(\alpha(\mathbf{x})|\mathbf{x})p(\mathbf{x})d\mathbf{x} \quad (1)$$

for en gitt desisjonsfunksjon $\alpha(\mathbf{x})$ med utfallene $\alpha_1, \alpha_2, \dots, \alpha_a$. Den totale risken skal minimaliseres ved å velge α_i slik at den betingede risken $R(\alpha(\mathbf{x})|\mathbf{x})$ er minimum for enhver \mathbf{x} . Dette leder til Bayes desisjonsregel, som kan skrives som

$$\text{Velg } \alpha_m \text{ hvis } R(\alpha_m|\mathbf{x}) \leq R(\alpha_j|\mathbf{x}), j = 1, \dots, a. \quad (2)$$

Utfallet av desisjonsfunksjonen er da α_m , dvs. $\alpha(\mathbf{x}) = \alpha_m$. Dette er den handling som gir minimum betinget risk, og samtidig minimum total risk (minimum av integralet i likning 1) og kalles derfor *minimum risk klassifisering*.

d) Den betingede risken forbundet med hver handling er her

$$\begin{aligned} R(\alpha_1|x) &= \lambda_{11}P(\omega_1|x) + \lambda_{12}P(\omega_2|x) \\ R(\alpha_2|x) &= \lambda_{21}P(\omega_1|x) + \lambda_{22}P(\omega_2|x). \end{aligned}$$

Desisjongsgrensen er da gitt ved

$$\begin{aligned} R(\alpha_1|x) &= R(\alpha_2|x) \\ \Downarrow \\ (\lambda_{11} - \lambda_{21})P(\omega_1|x) &= (\lambda_{22} - \lambda_{12})P(\omega_2|x). \end{aligned}$$

Innsatt de univariat normalfordelte klasser i denne oppgaven blir dette

$$\frac{\lambda_{11} - \lambda_{21}}{\sqrt{2\pi}\sigma} \exp \left[-\frac{1}{2} \left(\frac{x - \mu_1}{\sigma} \right)^2 \right] P(\omega_1) = \frac{\lambda_{22} - \lambda_{12}}{\sqrt{2\pi}\sigma} \exp \left[-\frac{1}{2} \left(\frac{x - \mu_2}{\sigma} \right)^2 \right] P(\omega_2),$$

der nevneren i Bayes formel er strøket på begge sider av likhetstegnet. Ved å ta logaritmen på begge sider og multiplisere ut kvadratuttrykkene i eksponenten, får man da

$$\begin{aligned} -\frac{1}{2\sigma^2}(x^2 - 2\mu_1x + \mu_1^2) + \ln[(\lambda_{11} - \lambda_{21})P(\omega_1)] &= -\frac{1}{2\sigma^2}(x^2 - 2\mu_2x + \mu_2^2) + \ln[(\lambda_{22} - \lambda_{12})P(\omega_2)] \\ \Downarrow \\ \frac{1}{2\sigma^2}(2\mu_1x - \mu_1^2) + \ln[(\lambda_{11} - \lambda_{21})P(\omega_1)] &= \frac{1}{2\sigma^2}(2\mu_2x - \mu_2^2) + \ln[(\lambda_{22} - \lambda_{12})P(\omega_2)] \\ \Downarrow \\ \frac{1}{2\sigma^2}(2\mu_1x - \mu_1^2) - \frac{1}{2\sigma^2}(2\mu_2x - \mu_2^2) &= \ln[(\lambda_{22} - \lambda_{12})P(\omega_2)] - \ln[(\lambda_{11} - \lambda_{21})P(\omega_1)] \\ \Downarrow \\ \frac{1}{2\sigma^2}(2\mu_1x - \mu_1^2) - \frac{1}{2\sigma^2}(2\mu_2x - \mu_2^2) &= \ln \frac{(\lambda_{22} - \lambda_{12})P(\omega_2)}{(\lambda_{11} - \lambda_{21})P(\omega_1)} \\ \Downarrow \\ 2(\mu_1 - \mu_2)x - (\mu_1^2 - \mu_2^2) &= 2\sigma^2 \ln \frac{(\lambda_{12} - \lambda_{22})P(\omega_2)}{(\lambda_{21} - \lambda_{11})P(\omega_1)} \end{aligned}$$

som kan løses mht. x , slik at terskelen blir

$$x_0 = \frac{\mu_1 + \mu_2}{2} + \frac{\sigma^2}{\mu_1 - \mu_2} \ln \left[\frac{(\lambda_{12} - \lambda_{22})P(\omega_2)}{(\lambda_{21} - \lambda_{11})P(\omega_1)} \right].$$

e) Se avsnitt 2.3 i forelesningsnotatene.

f) I dette tilfellet er $\lambda_{11} = \lambda_{22} = 0$ og $\lambda_{12} = \lambda_{21} = 1$. Terskelen forenkles da til

$$x_0 = \frac{\mu_1 + \mu_2}{2} + \frac{\sigma^2}{\mu_1 - \mu_2} \ln \frac{P(\omega_2)}{P(\omega_1)}.$$

Med like a priori sannsynligheter faller det siste leddet bort, og x_0 ligger da midt imellom μ_1 og μ_2 .

Skissen av fordelingene, med feilrate og desisjongsgrense blir tilsvarende figur 12 (på side 15) i forelesningsnotatene.

Oppgave 3

Parametriske metoder

a) Se avsnitt 3.1 på side 34 i forelesningsnotatene. Det forutsettes at samplene i treningssettet er innbyrdes uavhengige.

b) Med fordelingen $p(x|\theta)$ i oppgaveteksten blir likelihoodfunksjonen

$$P(\mathcal{X}|\theta) = \prod_{k=1}^n \left[\frac{1}{2} \theta^3 x_k^2 e^{-\theta x_k} \right].$$

Log-likelihoodfunksjonen blir da

$$\mathcal{L}(\theta) = \sum_{k=1}^n \ln \left[\frac{1}{2} \theta^3 x_k^2 e^{-\theta x_k} \right] = \sum_{k=1}^n [3 \ln \theta - \ln 2 + 2 \ln x_k - \theta x_k].$$

Maksimum-likelihood estimatet av θ finnes ved å sette den deriverte av log-likelihoodfunksjonen til null, dvs.

$$\frac{d\mathcal{L}(\theta)}{d\theta} = \sum_{k=1}^n \left[\frac{3}{\theta} - x_k \right] = 0,$$

som medfører at

$$\frac{3n}{\theta} = \sum_{k=1}^n x_k.$$

Estimatet blir da

$$\hat{\theta} = \frac{3n}{\sum_{k=1}^n x_k}.$$

Oppgave 4

Lineære diskriminantfunksjoner

- a) Se avsnitt 5.1.1 på side 65 i forelesningsnotatene.
- b) Se avsnitt 5.3 nederst på side 69 i forelesningsnotatene. Det utvidede egenskapsrommet har dimensjonen $d + 1$.
- c) Se avsnitt 5.7 og underavsnitt 5.7.1 i forelesningsnotatene.
- d) Her blir datamatriksen

$$Y = \begin{bmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 3 \\ -1 & -5 \\ -1 & -6 \\ -1 & -7 \end{bmatrix}.$$

Legg merke til at fortegnet på samplene fra klasse ω_2 er snudd (alternativt kan man snu fortegnet på de tre siste elementene i marginvektoren). Den pseudoinverse til Y kan beregnes f.eks. ved hjelp av Matlab, og blir

$$Y^\dagger = (Y^t Y)^{-1} Y^t = \begin{bmatrix} 0.5952 & 0.4524 & 0.3095 & -0.0238 & 0.1190 & 0.2619 \\ -0.1071 & -0.0714 & -0.0357 & -0.0357 & -0.0714 & -0.1071 \end{bmatrix}.$$

Med marginvektoren $\mathbf{b} = [1, 1, 1, 1, 1, 1]^t$ blir vektvektoren

$$\mathbf{a} = Y^\dagger \mathbf{b} = \begin{bmatrix} 1.7143 \\ -0.4286 \end{bmatrix}.$$


To-klasse diskriminantfunksjonen kan da skrives som $g(x) = 1.7143 - 0.4284x$. Terskelen mellom klassene er gitt ved nullpunktet for denne funksjonen, dvs.

$$x_0 = \frac{1.7143}{0.4284} = \underline{4}.$$

- e) Figuren på neste side viser treningssamplene, desisjongsgrensen og vektvektoren i det utvidede egenskapsrommet.

Samplene fra ω_1 ligger langs linjen $y_1 = 1$, mens fra samplene fra ω_2 ligger langs $y_1 = -1$ (fortegnet er snudd i henhold til fortegnskonvensjonen).

Alle sampler ligger på den positive siden av hyperplanet (linjen gjennom origo) og vektvektoren \mathbf{a} peker inn i desisjonsregionen for ω_1 , siden vi med fortegnskonvensjonen ønsker å få alle sampler på den positive siden av hyperplanet. Vektvektoren står normalt på desisjongsgrensen.



Oppgave 5

Ikke-ledet læring

a) Ikke-ledet læring går ut på å trene en klassifikator ved hjelp av et treningssett med *umerkede* sampler, dvs. klassetilhørigheten til treningssamplene er ukjent. En blandingstetthet er en vektet sum av de klassebetingede tetthetsfunksjonene, der vektene er klassenes a priori sannsynligheter.

b) Blandingstettheten for et problem med to klasser kan skrives som

$$p(\mathbf{x}|\boldsymbol{\theta}) = \sum_{i=1}^2 p(\mathbf{x}|\omega_i, \boldsymbol{\theta}_i)P(\omega_i) = p(\mathbf{x}|\omega_1, \boldsymbol{\theta}_1)P(\omega_1) + p(\mathbf{x}|\omega_2, \boldsymbol{\theta}_2)P(\omega_2).$$

Her er $p(\mathbf{x}|\omega_i, \boldsymbol{\theta}_i)$, $i = 1, 2$ komponenttetthetene, mens $P(\omega_i)$ er blandingsparametrene.

c) Se utledningen av likningssystemet for c klasser i avsnitt 7.1 (side 97) i forelesningsnotatene.

d) Innsetting av normalfordelingene

$$p(x_k|\omega_i, \mu_i) = \frac{1}{\sqrt{2\pi}} \exp \left[-\frac{1}{2} (x_k - \mu_i)^2 \right], \quad i = 1, 2$$

i likningssystemet

$$\sum_{k=1}^n P(\omega_i|x_k, \boldsymbol{\theta}) \nabla_{\boldsymbol{\theta}_i} \ln p(x_k|\omega_i, \boldsymbol{\theta}_i) = 0, \quad i = 1, 2,$$

gir da

$$\sum_{k=1}^n P(\omega_i|x_k, \mu_1, \mu_2) \frac{d}{d\mu_i} \left[-\frac{1}{2} (x - \mu_i)^2 - \ln \sqrt{2\pi} \right] = 0, \quad i = 1, 2,$$

som gir

$$\sum_{k=1}^n P(\omega_i|x_k, \mu_1, \mu_2) (x - \mu_i) = 0, \quad i = 1, 2.$$

Forventningsestimatene kan da uttrykkes ved

$$\hat{\mu}_i = \frac{\sum_{k=1}^n P(\omega_i|x_k, \hat{\mu}_1, \hat{\mu}_2) x_k}{\sum_{k=1}^n P(\omega_i|x_k, \hat{\mu}_1, \hat{\mu}_2)}, \quad i = 1, 2.$$

der

$$\begin{aligned} P(\omega_i|x_k, \hat{\mu}_1, \hat{\mu}_2) &= \frac{p(x_k|\omega_i, \hat{\mu}_i) P(\omega_i)}{\sum_{j=1}^2 p(x_k|\omega_j, \hat{\mu}_j) P(\omega_j)} \\ &= \frac{\exp\{-\frac{1}{2}(x_k - \hat{\mu}_i)^2\}}{\exp\{-\frac{1}{2}(x_k - \hat{\mu}_1)^2\} + \exp\{-\frac{1}{2}(x_k - \hat{\mu}_2)^2\}}, \quad i = 1, 2, \end{aligned}$$

etter innsetting av normalfordelingene og forkorting av like faktorer over og under brøkstreken. Her er $x_{k,k=1\dots n}$ de umerkede samplene i treningssettet.

Dette er implisitte uttrykk som kan løses ved iterasjon, som beskrevet på side 98 i forelesningsnotatene. Man velger startverdier for μ_1 og μ_2 og oppdaterer deretter aposteriorisannsynlighetene og forventningsestimatene rekursivt.