

Faglig kontakt under eksamen: Idar Dyrdal Tlf: 99579753

# EKSAMEN I TTK4205 MØNSTERGJENKJENNING

Mandag 10. desember 2012 Tid: 15.00-19.00

Sensur vil foreligge innen tre uker.

<u>Hjelpemiddelkombinasjon D</u>: Kalkulator med tomt minne tillatt.

Ingen trykte eller håndskrevne hjelpemidler tillatt.

Eksamensoppgava er på 3 sider innkludert forsiden.

## **Oppgave 1: Innledning**

- a) Skissér et typisk mønstergjenkjenningssystem og forklar hva som menes med egenskapsuttrekking og klassifisering.
- b) Gi et eksempel på et slikt system.
- c) Gi en kortfattet beskrivelse av noen hovedprinsipper som kan brukes til å konstruere en klassifikator ved ledet læring.
- d) Hvilke fremgangsmåter kan brukes til å estimere feilraten til en klassifikator?

### Oppgave 2: Bayesisk desisjonsteori

I et univariat (éndimensjonalt) klassifiseringsproblem med to klasser er tetthetsfunksjonene for de to klassene gitt ved normalfordelingene:

$$p(x|\omega_i) = \frac{1}{\sqrt{2\pi}\sigma_i} \exp\left[-\frac{1}{2}\left(\frac{x-\mu_i}{\sigma_i}\right)^2\right], \quad i=1, 2$$

der 
$$\mu_1 = 0$$
,  $\mu_2 = 2$  og  $\sigma_1 = \sigma_2 = 1$ .

- a) Konstruér en beslutningsregel basert på minimum feilrateprinsippet, dersom á posteriorisannsynlighetene for klassene er like, dvs. dersom  $P(\omega_1) = P(\omega_2) = 1/2$ .
- b) Lag en skisse som illustrerer feilraten.
- c) Anta at  $P(\omega_1)=2/3$  og  $P(\omega_2)=1/3$ . Hva blir beslutningsregelen i dette tilfellet?
- d) Anta at man i dette problemet ønsker å legge en høyere kostnad på feilklassifisering av sampler fra klasse  $\omega_2$  til klasse  $\omega_1$  enn motsatt, ved å velge kostfunksjonene  $\lambda(\alpha_1|\omega_2)=0.8$  og  $\lambda(\alpha_2|\omega_1)=0.2$ . Her er  $\alpha_i$  handlingen som består i å tilordne et sample til  $\omega_i$ , i=1,2. Kostnadene for riktig klassifisering settes lik null. Konstruer en minimum risk beslutningsregel med samme á posteriori sannsynligheter som i punkt c ovenfor.

#### **Oppgave 3:** Lineære diskriminantfunksjoner

- a) Skriv opp et sett av lineære diskriminantfunksjoner for et problem med c klasser, uttrykt ved vektvektor og skalarvekt, og formulér beslutningsregelen (forklar hvordan diskriminantfunksjonene brukes til klassifisering).
- b) Hvilke forenklinger kan gjøres for problemer med to klasser. Formulér beslutningsregelen i dette tilfellet.
- c) Definer utvidet egenskapsvektor  $\bar{y}$  og utvidet vektvektor  $\bar{a}$  og uttrykk diskriminantfunksjonen fra punkt b ovenfor ved hjelp av disse vektorene.

2

- d) Hva menes med begrepene lineær separabilitet, løsningsvektor og løsningsregion? Lag en skisse.
- e) Gi eksempler på algoritmer for trening av den utvidede vektvektoren ved hjelp av et treningssett.
- f) Beskriv fast-inkrement regelen og redegjør for når den konvergerer til en løsningsvektor.

## Oppgave 4: Ikke-ledet læring

- a) Hva er det som kjennetegner ikke-ledet læring (i motsetning til ledet læring), og hva menes med en blandingstetthet?
- b) Sett opp blandingstettheten for et toklasseproblem uttrykt ved tetthetsfunksjonene og á priorisannsynlighetene.
- c) Bruk maksimum likelihoodmetoden til å vise at likningssystemet for parametervektorene til de to klassene kan skrives som:

$$\sum_{k=1}^{n} P(\omega_{i}|\bar{x}_{k}, \bar{\theta}) \nabla_{\bar{\theta}_{i}} \ln p(\bar{x}_{k}|\omega_{i}, \bar{\theta}_{i}) = 0, \quad i = 1, 2$$

når á priorisannsynlighetene forutsettes kjente. Her er  $P(\omega_i | \bar{x}_k, \bar{\theta})$  á posteriorisannsynligheten til klasse  $\omega_i$  i  $\bar{x}_k$ . Treningssettet er gitt ved  $\chi = \{\bar{x}_1, ..., \bar{x}_n\}$ .

- d) Anta at klassene er univariat normalfordelte med like å priorisannsynligheter og standardavvik lik én for begge klasse (som i punkt 2a), men med ukjente forventningsverdier. Utled likningssystemet i dette tilfellet, og foreslå en løsningsmetode.
- e) Anta at treningssamplene danner to tette og godt adskilte klynger, og finn tilnærmede uttrykk for forventningsestimatene.

#### **Oppgave 5: Nærmeste-nabo metoder**

For et todimensjonalt klassifiseringsproblem med tre klasser har man et treningssett der:

$$\begin{split} \chi_1 &= \left[\begin{bmatrix} 1.0 \\ 1.0 \end{bmatrix}, \begin{bmatrix} 1.8 \\ 1.0 \end{bmatrix}, \begin{bmatrix} 2.0 \\ 0.0 \end{bmatrix}, \begin{bmatrix} 1.9 \\ 2.1 \end{bmatrix}\right] \quad \text{er samplesettet fra klasse} \quad \omega_1\,, \\ \chi_2 &= \left[\begin{bmatrix} 0.8 \\ 0.5 \end{bmatrix}, \begin{bmatrix} 0.5 \\ 1.2 \end{bmatrix}, \begin{bmatrix} 1.1 \\ 0.3 \end{bmatrix}\right] \quad \text{er samplesettet fra klasse} \quad \omega_2\,, \quad \text{og} \\ \chi_3 &= \left[\begin{bmatrix} 2.1 \\ 1.5 \end{bmatrix}, \begin{bmatrix} 2.2 \\ 1.8 \end{bmatrix}, \begin{bmatrix} 3.0 \\ 0.5 \end{bmatrix}, \begin{bmatrix} 2.5 \\ 0.8 \end{bmatrix}\right] \quad \text{er samplesettet fra klasse} \quad \omega_3\,. \end{split}$$

- a) Beskriv nærmeste-nabo regelen (NNR) og k-nærmeste-nabo regelen (k-NNR).
- b) Klassifisér det ukjente sampelet  $\bar{x}_0 = [2.0, 1.1]^t$  med NNR. Hva blir resultatet med k-NNR når k=3? Bruk Euclidsk avstand i egenskapsrommet.
- c) Angi en øvre grense for den asymptotiske feilraten til NNR som funksjon av den optimale (Bayesiske) feilraten. Lag en skisse.