# **UNIVERSITETET I OSLO**

## Det matematisk-naturvitenskapelige fakultet

Eksamen i: TEK5020 - Mønstergjenkjenning

**Eksamensdag: 2.12.2019** 

Tid for eksamen: 09:15 – 13:15 Oppgavesettet er på 4 sider

**Vedlegg: Ingen** 

Tillatte hjelpemidler: Ingen trykte eller håndskrevne hjelpemidler tillatt. Bestemt,

enkel kalkulator tillatt.

Kontroller at oppgavesettet er komplett før du begynner å besvare spørsmålene.

## Oppgave 1

## Innledning

- a) Beskriv et typisk mønstergjenkjenningssystem og forklar hva som menes med begrepene egenskapsuttrekking og klassifisering.
- b) Forklar hva som menes med begrepene *ledet læring* og *ikke-ledet læring*, og gjør rede for i hvilke situasjoner man bruker den ene eller andre fremgangsmåten.
- c) Forklar hva som menes med en *beslutningsregel* (desisjonsregel) og gi et eksempel på en slik regel.
- d) Nevn noen hovedprinsipper som kan brukes for å komme frem til en beslutningsregel ved ledet læring.

## Oppgave 2

### Beslutningsteori

- a) Sett opp *Bayes regel* (Bayes formel) for aposteriori sannsynlighet og forklar størrelsene som inngår.
- b) Formulér *minimum-feilrate* prinsippet for klassifisering.
- c) I et univariat (éndimensjonalt) toklasseproblem (der antall klasser c=2) er sannsynlighetstetthetsfunksjonene gitt ved de univariate normalfordelingene  $N(0,\sigma^2)$  for klasse  $\omega_1$  og  $N(1,\sigma^2)$  for  $\omega_2$ . Videre er klassenes apriori sannsynligheter gitt ved  $P(\omega_1)$  og  $P(\omega_2)$ . Vis at terskelen  $x_0$  som minimaliserer feilraten kan uttrykkes ved

$$x_0 = \frac{1}{2} + \sigma^2 \ln \frac{P(\omega_1)}{P(\omega_2)}.$$

- d) Lag en skisse som illustrerer feilraten og viser plasseringen av desisjonsgrensen for et tilfelle med like apriori sannsynligheter. Hva er terskelverdien i dette tilfellet?
- e) Hva blir terskelen  $x_0$ , uttrykt ved standardavviket  $\sigma$ , dersom  $P(\omega_1) = 1/3$  og  $P(\omega_2) = 2/3$ ?

#### **Oppgave 3**

Parametriske metoder

a) Beskriv *maksimum-likelihood* (ML) metoden for estimering av parametervektoren  $\boldsymbol{\theta}$  i en gitt tetthetsfunksjon  $p(\boldsymbol{x}|\boldsymbol{\theta})$  ved ledet læring, og vis at estimatet kan finnes ved å løse likningssystemet

$$\sum_{k=1}^{n} \nabla_{\boldsymbol{\theta}} \ln p(\boldsymbol{x}_{k} \mid \boldsymbol{\theta}) = \mathbf{0}$$

med hensyn på  $\boldsymbol{\theta}$ , der  $\boldsymbol{x}_k, k = 1, \dots, n$  er egenskapsvektorene i treningssettet.

b) Finn ML-estimatet av parameteren  $\theta$  i den univariate eksponentialfordelingen gitt ved

$$p(x|\theta) = \begin{cases} \theta e^{-\theta x} & x \ge 0\\ 0 & ellers, \end{cases}$$

der  $\theta > 0$  og treningssettet er gitt ved  $\mathcal{X} = \{x_1, ..., x_n\}$ .

## **Oppgave 4**

Diskriminantfunksjoner

- a) Hva menes med diskriminantfunksjoner, og hvordan brukes slike funksjoner i forbindelse med klassifisering?
- b) I et todimensjonalt klassifiseringsproblem med tre klasser, er de klassebetingede tetthetsfunksjonene antatt å være multivariate normalfordelinger

$$p(\mathbf{x}|\omega_i) = \frac{1}{(2\pi)^{d/2}|\Sigma_i|^{1/2}} \exp\left[-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu}_i)^t \Sigma_i^{-1}(\mathbf{x} - \boldsymbol{\mu}_i)\right], \quad i = 1, 2, 3.$$

Anta videre at kovariansmatrisene er like for alle klasser, dvs.  $\Sigma_1 = \Sigma_2 = \Sigma_3 = \Sigma$ , der

$$\Sigma = \begin{bmatrix} 3 & 1 \\ 1 & 2 \end{bmatrix},$$

og at forventningsvektorene for klassene er

$$\boldsymbol{\mu}_1 = \begin{bmatrix} -2 \\ 5 \end{bmatrix}, \quad \boldsymbol{\mu}_2 = \begin{bmatrix} 2 \\ 3 \end{bmatrix} \quad \text{og} \quad \boldsymbol{\mu}_3 = \begin{bmatrix} 3 \\ -2 \end{bmatrix}.$$

Utled et sett av diskriminantfunksjoner for dette problemet. Ta utgangspunkt i minimum-feilrate prinsippet og anta like apriori sannsynligheter for de tre klassene.

- c) Hvorfor er diskriminantfunksjonene *lineære* i dette tilfellet, og hvor mange desisjonsregioner gir de opphav til?
- d) Bruk diskriminantfunksjonene til å klassifisere et ukjent objekt representert ved egenskapsvektoren

$$\mathbf{x}_0 = \begin{bmatrix} 1 \\ -1 \end{bmatrix}$$
.

#### **Oppgave 5**

Ikke-parametriske metoder

- a) Beskriv prinsippet for *ikke-parametrisk* tetthetsestimering og sett opp et estimat for sannsynlighetstettheten i et vilkårlig punkt x i egenskapsrommet, basert på et treningssett med n egenskapsvektorer trukket fra den klassen tettheten skal estimeres for.
- b) Gjør rede for hvordan slike estimater kan brukes til klassifisering av ukjente sampler, og nevn to hovedtyper av metoder.
- c) Beskriv *nærmeste-nabo regelen* (NNR) og *k-nærmeste-nabo regelen* (k-NNR) for klassifisering.
- d) For et todimensjonalt klassifiseringsproblem med tre klasser  $\omega_1$ ,  $\omega_2$  og  $\omega_3$  er treningssettet gitt ved

$$\mathscr{X}_1 = \left\{ \begin{bmatrix} 1 \\ 9 \end{bmatrix}, \begin{bmatrix} 2 \\ 7 \end{bmatrix}, \begin{bmatrix} 3 \\ 8 \end{bmatrix}, \begin{bmatrix} 4 \\ 8 \end{bmatrix}, \begin{bmatrix} 5 \\ 6 \end{bmatrix} \right\} \quad \text{(egenskapsvektorer fra $\omega_1$),}$$

$$\mathscr{X}_2 = \left\{ \begin{bmatrix} 3 \\ 5 \end{bmatrix}, \begin{bmatrix} 5 \\ 7 \end{bmatrix}, \begin{bmatrix} 6 \\ 4 \end{bmatrix}, \begin{bmatrix} 7 \\ 6 \end{bmatrix} \right\} \quad \text{(egenskapsvektorer fra $\omega_2$)}$$

og

$$\mathscr{X}_3 = \left\{ \begin{bmatrix} 4 \\ 3 \end{bmatrix}, \begin{bmatrix} 5 \\ 1 \end{bmatrix}, \begin{bmatrix} 5 \\ 4 \end{bmatrix}, \begin{bmatrix} 7 \\ 2 \end{bmatrix}, \begin{bmatrix} 8 \\ 4 \end{bmatrix} \right\}$$
 (egenskapsvektorer fra  $\omega_3$ ).

Bruk NNR til å klassifisere et ukjent objekt i punktet  $[4,6]^t$  i egenskapsrommet. Hva blir resultatet med k-NNR der k = 3? Bruk Euclidsk avstand i egenskapsrommet.

e) Gi en kortfattet redegjørelse for fordeler og ulemper ved ikke-parametriske metoder.