

# TEK5020/9020 Mønstergjenkjenning Høsten 2023

Forelesning 2 – Beslutningsteori (1)

Idar Dyrdal (idar.dyrdal@its.uio.no)

UiO : Institutt for teknologisystemer

16. august 2023

# Innhold i kurset

- Introduksjon til mønstergjenkjenning
- [Beslutningsteori \(desisjonsteori\)](#)
- Parametriske metoder
- Ikke-parametriske metoder
- Lineære og generaliserte diskriminantfunksjoner
- Evaluering av klassifikatorer
- Ikke-ledet læring
- Klyngeanalyse.

# Beslutningsteori – grunnleggende begreper

Objekter skal tilordnes *klasser/tilstander*:

$$\omega_1, \omega_2, \dots, \omega_c$$

der  $c$  er antall klasser i problemet. Til hver klasse hører en *a priori sannsynlighet*:

$$P(\omega_1), P(\omega_2), \dots, P(\omega_c)$$

som er sannsynligheten for at hver klasse skal opptre (før målinger er foretatt).

Til hver klasse hører også *klassebetingede sannsynlighetstetthetsfunksjoner*:


$$p(\mathbf{x}|\omega_i), i = 1, \dots, c.$$

Her er vektoren:

$$\mathbf{x} = [x_1, x_2, \dots, x_d]^t$$

en målt *egenskapsvektor* for det aktuelle objektet.

# Sannsynlighetstetthetsfunksjon



Eksempel på tetthetsfunksjon. Det grønne arealet tilsvarer sannsynligheten for at et vilkårlig sample skal opptre med egenskapsverdi  $x$  i intervallet mellom  $a$  og  $b$ .

## Bayes regel

Bayes regel for *a posteriori sannsynlighet*:

$$P(\omega_i|\mathbf{x}) = \frac{p(\mathbf{x}|\omega_i)P(\omega_i)}{\sum_{j=1}^c p(\mathbf{x}|\omega_j)P(\omega_j)}, i = 1, \dots, c$$

knytter sammen a priori sannsynligheter og klassebetingede tetthetsfunksjoner.

$P(\omega_i|\mathbf{x})$  er sannsynligheten for at klasse  $\omega_i$  skal opptre, gitt den målte egenskapsvektoren  $\mathbf{x}$ , dvs. sannsynligheten for klasse  $\omega_i$  *etter* målingen  $\mathbf{x}$ .

Summen av a posteriorisannsynlighetene over alle klasser er én, dvs.

$$\sum_{i=1}^c P(\omega_i|\mathbf{x}) = 1.$$

# Handlinger

*Handlinger* (actions):

$$\alpha_1, \alpha_2, \dots, \alpha_a$$

er noe som utføres på bakgrunn av den målte egenskapsvektoren.

Hvor mange handlinger?

- Vanligvis er  $a = c$ , dvs. én-til-én sammenheng mellom klasser og handlinger (handlingen  $\alpha_i$  består i å klassifisere til klasse  $\omega_i$ ),
- Generelt er  $a \neq c$ , f.eks.  $a = c + 1$  der handling  $\alpha_{c+1}$  tilsvarer forkasting (ingen klassifisering).

*Desisjonsfunksjonen*:

$$\alpha(\mathbf{x}) \rightarrow \alpha_1, \alpha_2, \dots, \alpha_a$$

er en funksjon av egenskapsvektoren  $\mathbf{x}$ , som har én av de mulige handlingene som utfall.

# Kostnader knyttet til handlinger

*Kostfunksjonen:*

$$\lambda(\alpha_i|\omega_j), \text{ der } i = 1, \dots, a \text{ og } j = 1, \dots, c,$$

angir kostnaden (tapet) ved å velge handlingen  $\alpha_i$  når  $\omega_j$  er sann klasse.

Det kan f.eks. være et større tap forbundet ved å klassifisere bjørk som ask enn omvendt, slik at kostnadene for disse tilfellene kan være

$$\lambda(\text{velg bjørk}|\text{ask}) = 1$$

$$\lambda(\text{velg ask}|\text{bjørk}) = 10$$

mens kostnadene for riktig valg av handling som oftest vil settes til null, dvs.

$$\lambda(\text{velg bjørk}|\text{bjørk}) = \lambda(\text{velg ask}|\text{ask}) = 0.$$

# Risiko knyttet til handlinger

*Betinget risk* (forventet tap) er kostnaden forbundet ved en gitt handling, gitt en måling (dvs. egenskapsvektoren for et ukjent objekt)

$$R(\alpha_i|\mathbf{x}) = \sum_{j=1}^c \lambda(\alpha_i|\omega_j) P(\omega_j|\mathbf{x}), i=1, \dots, a.$$

*Total risk* er gitt ved

$$R = \int_{\mathbb{R}^d} R(\alpha(\mathbf{x})|\mathbf{x}) p(\mathbf{x}) d\mathbf{x}$$

for en gitt desisjonsfunksjon  $\alpha(\mathbf{x})$  med utfallene  $\alpha_1, \alpha_2, \dots, \alpha_a$ . Den totale risiken skal minimaliseres ved å velge  $\alpha_i$  slik at den betingede risiken  $R(\alpha(\mathbf{x})|\mathbf{x})$  er minimum for enhver  $\mathbf{x}$ .



# Bayes desisjonsregel

Minimalisering av total risk  $R$  leder til *Bayes desisjonsregel*, som kan skrives som

$$\text{Velg } \alpha_m \text{ hvis } R(\alpha_m | \mathbf{x}) \leq R(\alpha_j | \mathbf{x}), j = 1, \dots, a.$$

Utfallet av desisjonsfunksjonen er da  $\alpha_m$ , dvs.

$$\alpha(\mathbf{x}) = \alpha_m.$$

Dette er det valg av handling som gir minimum betinget risk og sikrer minimum total risk, dvs. *minimum-risk klassifisering*.

## Bayes desisjonsregel for to klasser

La klassene være  $\omega_1$  og  $\omega_2$  og de tilhørende handlingene henholdsvis  $\alpha_1$  og  $\alpha_2$ , slik at handlingene her består i å velge den ene eller den andre klassen, dvs.

$$\alpha_i : \mathbf{x} \rightarrow \omega_i$$

der  $a = c = 2$  og  $\alpha_1$  og  $\alpha_2$  er de mulige utfallene. La kostfunksjonen være gitt ved

$$\lambda(\alpha_i | \omega_j) = \lambda_{ij} \text{ der } \lambda_{ij} > \lambda_{ji}, i \neq j.$$

Den betingede risken forbundet med hver handling blir da

$$R(\alpha_1 | \mathbf{x}) = \lambda_{11}P(\omega_1 | \mathbf{x}) + \lambda_{12}P(\omega_2 | \mathbf{x})$$

$$R(\alpha_2 | \mathbf{x}) = \lambda_{21}P(\omega_1 | \mathbf{x}) + \lambda_{22}P(\omega_2 | \mathbf{x}).$$

## Bayes desisjonsregel for to klasser (forts.)

Beslutningsregelen blir derfor

Velg  $\alpha_1$  hvis  $R(\alpha_1|\mathbf{x}) \leq R(\alpha_2|\mathbf{x})$ , ellers  $\alpha_2$

$\Downarrow$

Velg  $\omega_1$  hvis  $(\lambda_{11} - \lambda_{21})P(\omega_1|\mathbf{x}) \leq (\lambda_{22} - \lambda_{12})P(\omega_2|\mathbf{x})$ ,  $\omega_2$  ellers

$\Downarrow$

Velg  $\omega_1$  hvis  $\frac{P(\omega_1|\mathbf{x})}{P(\omega_2|\mathbf{x})} \geq \underbrace{\frac{\lambda_{12} - \lambda_{22}}{\lambda_{21} - \lambda_{11}}}_{>0}$ ,  $\omega_2$  ellers.

Her er ulikhetstegnet snudd fordi  $\lambda_{11} - \lambda_{21} < 0$ .

## Bayes desisjonsregel for to klasser (forts.)

Ved bruk av Bayes regel kan den foregående ulikheten skrives som

$$\frac{p(\mathbf{x}|\omega_1)P(\omega_1)}{p(\mathbf{x}|\omega_2)P(\omega_2)} \geq \frac{\lambda_{12} - \lambda_{22}}{\lambda_{21} - \lambda_{11}}$$

Dette gir beslutningsregelen

$$\text{Velg } \omega_1 \text{ hvis } \frac{p(\mathbf{x}|\omega_1)}{p(\mathbf{x}|\omega_2)} \geq \frac{\lambda_{12} - \lambda_{22}}{\lambda_{21} - \lambda_{11}} \frac{P(\omega_2)}{P(\omega_1)}, \omega_2 \text{ ellers.}$$

Terskelen på høyre side av ulikhetstegnet er uavhengig av egenskapsvektoren  $\mathbf{x}$  og er forøvrig  $> 0$ .

## Bayes desisjonsregel for to klasser (forts.)

Anta spesialtilfellet (egentlig et ganske vanlig valg)

$$\lambda_{ii} = 0, \lambda_{ij, i \neq j} > 0,$$

slik at riktig klassifisering er uten kostnad og alle feilklassifiseringer har en endelig kostnad. Desisjonsregelen reduseres derved til

$$\text{Velg } \omega_1 \text{ hvis } \frac{P(\omega_1|\mathbf{x})}{P(\omega_2|\mathbf{x})} \geq \frac{\lambda_{12}}{\lambda_{21}}, \omega_2 \text{ ellers.}$$

Hvis det er mest kostbart å velge  $\omega_1$  hvis  $\omega_2$  er sann (dvs.  $\lambda_{12} \geq \lambda_{21}$ ) innebære dette at  $P(\omega_1|\mathbf{x})$  må overskride  $P(\omega_2|\mathbf{x})$  med faktoren  $\lambda_{12}/\lambda_{21} > 1$  før  $\omega_1$  kan velges.

Omskriving ved hjelp av Bayes regel gir her beslutningsregelen

$$\text{Velg } \omega_1 \text{ hvis } \frac{p(\mathbf{x}|\omega_1)}{p(\mathbf{x}|\omega_2)} \geq \frac{\lambda_{12}}{\lambda_{21}} \frac{P(\omega_2)}{P(\omega_1)}, \omega_2 \text{ ellers.}$$

Terskelen på høyre side er også her  $> 0$  og uavhengig av  $\mathbf{x}$ .

## Minimum-feilrate klassifisering

Ved å velge en null-én kostfunksjon (og sette  $a=c$ ), dvs.

$$\lambda(\alpha_i|\omega_j) = \lambda_{ij} = \begin{cases} 0 & i = j \quad (\text{ingen kost for riktig klassifisering}) \\ 1 & i \neq j \quad (\text{lik kost for alle typer feilklassifiseringer}), \end{cases}$$



forenkles den betingede risken til

$$\begin{aligned} R(\alpha_i|\mathbf{x}) &= \sum_{j=1}^c \lambda_{ij} P(\omega_j|\mathbf{x}) = \sum_{j=1, j \neq i}^c P(\omega_j|\mathbf{x}) \\ &= 1 - P(\omega_i|\mathbf{x}), \text{ siden } \sum_{j=1}^c P(\omega_j|\mathbf{x}) = 1, \end{aligned}$$

som gir *minimum feilrate* desisjonsregelen

$\text{Velg } \omega_i \text{ hvis } P(\omega_i|\mathbf{x}) \geq P(\omega_j|\mathbf{x}), j = 1, \dots, c.$

# A posteriori sannsynlighet – minimum feilrate klassifisering



Plott av tetthetsfunksjoner (til venstre) og a posteriori sannsynligheter (til høyre) for to klasser. Optimal desisjonsgrense ( $x_0$ ) der de a posteriori sannsynlighetene for klassene er like ( $P(\omega_1|x) = P(\omega_2|x) = 0,5$ ).


# Maksimum-tiltro klassifisering

La oss se på spesialtilfellet med like a priori sannsynligheter, dvs.

$$P(\omega_i) = 1/c.$$

Da forenkles minimum-feilrate regelen til *maksimum tiltro* (maximum likelihood) regelen

Velg  $\omega_i$  hvis  $p(\mathbf{x}|\omega_i) \geq p(\mathbf{x}|\omega_j)$ ,  $j = 1, \dots, c$ .



I dette tilfellet inngår altså kun tetthetsfunksjonene i beslutningsregelen.



## Feilrate og desisjonsregioner

Feilsannsynligheten (feilraten) kan skrives som

$P(\text{feil}) = 1 - P(\text{rett})$ , der sannsynligheten for riktig valg er

$$\begin{aligned} P(\text{rett}) &= \sum_{j=1}^c P(\mathbf{x} \in \mathbb{R}_j, \omega_j) = \sum_{j=1}^c P(\mathbf{x} \in \mathbb{R}_j | \omega_j) P(\omega_j) \\ &= \sum_{j=1}^c \left\{ \int_{\mathbb{R}_j} p(\mathbf{x} | \omega_j) d\mathbf{x} \right\} P(\omega_j) = \sum_{j=1}^c \int_{\mathbb{R}_j} p(\mathbf{x} | \omega_j) P(\omega_j) d\mathbf{x}. \end{aligned}$$

$P(\text{rett})$  maksimaliseres (og feilraten  $P(\text{feil})$  minimaliseres) ved å velge  $\mathbb{R}_i$ ,  $i = 1, \dots, c$  slik at


$$p(\mathbf{x} | \omega_i) P(\omega_i) \geq p(\mathbf{x} | \omega_j) P(\omega_j), \quad j = 1, \dots, c \text{ for alle } \mathbf{x} \in \mathbb{R}_i.$$

De optimale desisjonsgrensene går da gjennom punkter  $\mathbf{x}$  der

$$p(\mathbf{x} | \omega_i) P(\omega_i) = p(\mathbf{x} | \omega_j) P(\omega_j) \text{ for } i \neq j$$


forutsatt at  $p(\mathbf{x} | \omega_i) P(\omega_i)$  er maksimum over alle  $\omega_1, \dots, \omega_c$ .

# Univariat toklasseproblem – optimale desisjonsregioner




Tetthetsfunksjoner for to klasser, veiet med a priori sannsynlighet. Den stiplede linjen markerer terskelen der de veiede tetthetene er like.

# Univariat toklasseproblem – minimum feilrate




Tetthetsfunksjoner for to klasser, veiet med a priori sannsynlighet. Det grønne arealet viser feilraten med den optimale desisjonsgrensen (stiplet linje).

## Feilrate med suboptimal desisjonsgrense




Tetthetsfunksjoner for to klasser, veiet med a priori sannsynlighet. Det røde arealet tilsvarer den ekstra feilraten ved et suboptimalt valg av desisjonsgrense.

# Inndeling i desisjonsregioner – univariat problem med tre klasser



Veiede tetthetsfunksjoner for problem med tre klasser. Desisjonsgrensene deler det éndimensjonale egenskapsrommet inn i tre desisjonsregioner, men er *ikke* optimale.

## Optimale desisjongsgrenser – minimum feilrate



Veiede tetthetsfunksjoner for problem med tre klasser. Desisjongsgrensene gir en optimal inndeling av egenskapsrommet i tre desisjonsregioner.

## Eksempel – desisjongsgrense mellom to klasser

I et endimensjonalt (univariat) problem med to klasser  $\omega_1$  og  $\omega_2$  og tilhørende handlinger  $\alpha_1$  og  $\alpha_2$  (antall handlinger lik antall klasser), er fordelingsfunksjonene på formen


$$p(x|\theta) = \theta^2 x e^{-\theta x},$$

der  $\theta > 0$  og  $x \geq 0$ .

Parameteren  $\theta$  bestemmer fordelingen.

La de to klassene ha parametrene  $\theta_1$  og  $\theta_2$  og apriorisannsynlighetene  $P(\omega_1)$  og  $P(\omega_2)$ .

Erlang-2 fordeling med  $\theta = 1$



## Eksempel – desisjonsgrense mellom to klasser (forts.)

Anta kostnadene

- $\lambda_{11} = \lambda_{22} = 0$  (null kostnad for feilfri klassifisering),
- $\lambda_{12} > 0$  og  $\lambda_{21} > 0$  (kostnad for feilklassifiseringer større enn null).

Terskelen (desisjonsgrensen)  $x_0$  som minimaliserer den totale risken finner vi der den betingede risken for hver av handlingene er like, dvs.

$$R(\alpha_1|x_0) = R(\alpha_2|x_0).$$

Den betingede risken forbundet med handlingene blir, etter innsetting for kostnadene og aposteriorisannsynlighetene, i dette tilfellet

$$R(\alpha_1|x) = \lambda_{11}P(\omega_1|x) + \lambda_{12}P(\omega_2|x) = \lambda_{12}P(\omega_2|x) = \lambda_{12}\theta_2^2xe^{-\theta_2x}P(\omega_2)/p(x),$$

$$R(\alpha_2|x) = \lambda_{21}P(\omega_1|x) + \lambda_{22}P(\omega_2|x) = \lambda_{21}P(\omega_1|x) = \lambda_{21}\theta_1^2xe^{-\theta_1x}P(\omega_1)/p(x).$$



## Eksempel – desisjongsgrense mellom to klasser (forts.)

Terskelen kan da bestemmes ved å sette disse størrelsene like:

$$\begin{aligned} R(\alpha_1|x) &= R(\alpha_2|x) \\ \Downarrow \\ \lambda_{12}\theta_2^2 x e^{-\theta_2 x} P(\omega_2) &= \lambda_{21}\theta_1^2 x e^{-\theta_1 x} P(\omega_1) \\ \Downarrow \\ e^{(\theta_1 - \theta_2)x} &= \frac{\lambda_{21}\theta_1^2 P(\omega_1)}{\lambda_{12}\theta_2^2 P(\omega_2)}. \end{aligned}$$

Ved å ta logaritmen på begge sider av likhetstegnet kan det løses ut for  $x$ , slik at terskelen blir

$$x_0 = \frac{1}{\theta_1 - \theta_2} \ln \left[ \frac{\lambda_{21}\theta_1^2 P(\omega_1)}{\lambda_{12}\theta_2^2 P(\omega_2)} \right].$$

## Eksempel – desisjongsgrense mellom to klasser (forts.)


Anta nå

- $\theta_1 = 1$  og  $\theta_2 = 2$ ,
- $\lambda_{12} = \lambda_{21}$ ,
- $P(\omega_1) = P(\omega_2)$ .

Innsetting i uttrykket for  $x_0$  gir da resultatet

$$x_0 = -\ln[1/2^2] = \ln(4) \approx 1,3863.$$

Figuren t.h. viser fordelingene, terskelen og desisjonsregionene i dette tilfellet.



## Diskriminantfunksjoner

Diskriminantfunksjoner er et sett av funksjoner av egenskapsvektoren  $\mathbf{x}$ :


$$g_i(\mathbf{x}), i = 1, \dots, c \quad (\text{ n funksjon for hver klasse})$$

slik at beslutningsregler kan skrives p  generell (kanonisk) form:

$$\text{Velg } \omega_i \text{ hvis } g_i(\mathbf{x}) = \max_j \{g_j(\mathbf{x})\}$$

Desisjongrenser g r gjennom punkter der to funksjoner er like, og st rre enn verdien til de  vrige diskriminantfunksjoner, dvs. dersom

$$g_i(\mathbf{x}) = g_j(\mathbf{x}) \text{ n r } \mathbb{R}_i \text{ og } \mathbb{R}_j \text{ er naboer.}$$



Klassifiseringsmaskin.

## Diskriminantfunksjoner (forts.)

Eksempler på diskriminantfunksjoner:

$$g_i(\mathbf{x}) = P(\omega_i|\mathbf{x}) = \frac{p(\mathbf{x}|\omega_i)P(\omega_i)}{\sum_{j=1}^c p(\mathbf{x}|\omega_j)P(\omega_j)}$$

$$g_i(\mathbf{x}) = p(\mathbf{x}|\omega_i)P(\omega_i)$$

$$g_i(\mathbf{x}) = \ln [p(\mathbf{x}|\omega_i)P(\omega_i)] = \ln p(\mathbf{x}|\omega_i) + \ln P(\omega_i)$$

$$g_i(\mathbf{x}) = -R(\alpha_i|\mathbf{x}).$$

Legg merke til at bruk av logaritmen (som i det tredje eksempelet) ofte gir en enklere beslutningsregel, spesielt dersom tetthetsfunksjonene er på eksponensiell form.

Bruk av logaritmen (eller en annen monotont voksende funksjon) på f.eks. forholdet mellom a posteriori sannsynlighetene, forandrer heller ikke rangeringen av diskriminantfunksjonen og derved ikke valg av klasse.

## Diskriminantfunksjoner for toklasseproblemet

For to klasser kan man for enkelhets skyld innføre en felles diskriminantfunksjon

$$g(\mathbf{x}) = g_1(\mathbf{x}) - g_2(\mathbf{x})$$

slik at beslutningsregelen for toklasseproblemet kan skrives som

Velg  $\omega_1$  hvis  $g(\mathbf{x}) > 0$  og  $\omega_2$  ellers.

Mulige diskriminantfunksjoner for to klasser er

$$g(\mathbf{x}) = P(\omega_1|\mathbf{x}) - P(\omega_2|\mathbf{x})$$

$$g(\mathbf{x}) = \ln \frac{P(\omega_1|\mathbf{x})}{P(\omega_2|\mathbf{x})} = \ln \frac{p(\mathbf{x}|\omega_1)}{p(\mathbf{x}|\omega_2)} + \ln \frac{P(\omega_1)}{P(\omega_2)}.$$

# Normalfordelingen

Univariat normalfordeling (Gaussfordelingen):

$$p(x|\mu, \sigma^2) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}} = N(\mu, \sigma^2)$$


der  $\mu$  er forventningsverdien og  $\sigma^2$  variansen.

Multivariat normalfordeling:

$$p(\mathbf{x}|\boldsymbol{\mu}, \Sigma) = \frac{1}{(2\pi)^{d/2}|\Sigma|^{1/2}} \exp\left[-\frac{1}{2}(\mathbf{x}-\boldsymbol{\mu})^t \Sigma^{-1}(\mathbf{x}-\boldsymbol{\mu})\right] = N(\boldsymbol{\mu}, \Sigma)$$

der  $\boldsymbol{\mu}$  er forventningsvektoren og  $\Sigma$  er kovariansmatrisen.

# Univariat normalfordeling



Klassebetinget normalfordeling for klasse  $\omega_i$ , der forventningsverdien er  $\mu_i$  og standardavviket er  $\sigma_i$ .

## Diskriminantfunksjoner for univariate normalfordelinger

Anta  $c$  univariat normalfordelte klasser, slik at

$$p(x|\omega_i) = \frac{1}{\sqrt{2\pi}\sigma_i} \exp \left[ -\frac{1}{2} \left( \frac{x - \mu_i}{\sigma_i} \right)^2 \right], i = 1, \dots, c$$

Et mulig valg for diskriminantfunksjonene er da

$$\begin{aligned} g_i(x) &= \ln P(\omega_i|x) \\ &= \ln p(x|\omega_i) + \ln P(\omega_i) - \ln p(x) \\ &= -\frac{1}{2} \left( \frac{x - \mu_i}{\sigma_i} \right)^2 - \frac{1}{2} \ln 2\pi - \ln \sigma_i + \ln P(\omega_i) - \ln p(x). \end{aligned}$$



## Diskriminantfunksjoner for univariate normalfordelinger (forts.)

Etter fjerning av ledd som er like for alle klasser, reduseres dette til

$$\begin{aligned} g'_i(x) &= \underbrace{-\frac{1}{2\sigma_i^2}}_{a_i} x^2 + \underbrace{\frac{\mu_i}{\sigma_i^2}}_{b_i} x - \underbrace{\left( \frac{\mu_i^2}{2\sigma_i^2} + \ln \sigma_i - \ln P(\omega_i) \right)}_{c_i} \\ &= \underline{\underline{a_i x^2 + b_i x + c_i}}, i = 1, \dots, c \end{aligned}$$

Dette er *kvadratiske* diskriminantfunksjoner (kvadratiske med hensyn til egenskapen  $x$ ).

## Diskriminantfunksjoner for univariate normalfordelinger (forts.)

For to klasser kan diskriminantfunksjonene slås sammen til én felles funksjon  $g(x)$  for begge klassene, slik at

$$g(x) = g_1(x) - g_2(x)$$

$$= \underbrace{\frac{1}{2} \left( \frac{1}{\sigma_2^2} - \frac{1}{\sigma_1^2} \right)}_a x^2 + \underbrace{\left( \frac{\mu_1}{\sigma_1^2} - \frac{\mu_2}{\sigma_2^2} \right)}_b x + \underbrace{\frac{1}{2} \left( \frac{\mu_2^2}{\sigma_2^2} - \frac{\mu_1^2}{\sigma_1^2} \right) + \ln \frac{\sigma_2 P(\omega_1)}{\sigma_1 P(\omega_2)}}_c$$

$$= \underline{\underline{ax^2 + bx + c}},$$

som også er en kvadratisk diskriminantfunksjon.

## Diskriminantfunksjoner for univariate normalfordelinger (forts.)

Koeffisientene  $a$ ,  $b$  og  $c$  er her gitt ved

$$a = \frac{1}{2} \left( \frac{1}{\sigma_2^2} - \frac{1}{\sigma_1^2} \right)$$

$$b = \left( \frac{\mu_1}{\sigma_1^2} - \frac{\mu_2}{\sigma_2^2} \right)$$

$$c = \frac{1}{2} \left( \frac{\mu_2^2}{\sigma_2^2} - \frac{\mu_1^2}{\sigma_1^2} \right) + \ln \frac{\sigma_2 P(\omega_1)}{\sigma_1 P(\omega_2)}.$$

## Diskriminantfunksjoner for univariate normalfordelinger (forts.)


La oss se på spesialtilfellet  $\mu_1 = \mu_2 = 0$ . Dette gir

$$g(x) = ax^2 + c,$$

og likningen  $g(x) = 0$  for desisjonsgrensene gir løsningen

$$x_0 = \pm \sqrt{-\frac{c}{a}},$$

dvs. to terskler på tallinjen.



Tersklene deler egenskapsrommet opp i to desisjonsregioner. Klassen med minst varians får en enkeltsammenhengende region omkring origo, mens den andre klassen får en todelt region for  $x < -|x_0|$  til venstre og  $x > |x_0|$  til høyre.

## Diskriminantfunksjoner for univariate normalfordelinger (forts.)

La oss nå se på spesialtilfellet  $\sigma_1 = \sigma_2 = \sigma$ .


Diskriminantfunksjonen blir da

$$g(x) = \underbrace{\frac{1}{\sigma^2}(\mu_1 - \mu_2)}_b x + \underbrace{\frac{\mu_2^2 - \mu_1^2}{2\sigma^2} + \ln \frac{P(\omega_1)}{P(\omega_2)}}_c = \underline{\underline{bx + c}}.$$

Dette er en lineær diskriminantfunksjon. Desisjonsgrensen finnes ved å løse likningen  $g(x) = 0$ , som i dette tilfellet gir:

$$x_0 = -\frac{c}{b} = -\frac{\frac{\mu_2^2 - \mu_1^2}{2\sigma^2} + \ln \frac{P(\omega_1)}{P(\omega_2)}}{\frac{1}{\sigma^2}(\mu_1 - \mu_2)} = -\frac{\mu_2^2 - \mu_1^2 + 2\sigma^2 \ln \frac{P(\omega_1)}{P(\omega_2)}}{2(\mu_1 - \mu_2)}.$$

## Diskriminantfunksjoner for univariate normalfordelinger (forts.)



To klasser med like varianser og forskjellige forventningsverdier.

## Multivariat normalfordeling

Den multivariate normalfordelingen (normalfordeling i et rom av vilkårlig dimensjon) er gitt ved

$$p(\mathbf{x}) = \frac{1}{(2\pi)^{d/2} |\Sigma|^{1/2}} e^{-\frac{1}{2}(\mathbf{x}-\boldsymbol{\mu})^t \Sigma^{-1}(\mathbf{x}-\boldsymbol{\mu})} = N(\boldsymbol{\mu}, \Sigma)$$

Her er  $\boldsymbol{\mu}$  forventningsvektoren

$$\boldsymbol{\mu} = E\{\mathbf{x}\} = \begin{bmatrix} \mu_1 \\ \vdots \\ \mu_d \end{bmatrix} \quad (d \text{ komponenter})$$

og  $\Sigma$  kovariansmatrisen

$$\Sigma = E\{(\mathbf{x} - \boldsymbol{\mu})(\mathbf{x} - \boldsymbol{\mu})^t\} = \begin{bmatrix} \sigma_{11} & \sigma_{12} & \dots & \sigma_{1d} \\ \vdots & \vdots & & \vdots \\ \sigma_{d1} & \sigma_{d2} & \dots & \sigma_{dd} \end{bmatrix} \quad (d \times d \text{ komponenter}).$$

## Multivariat normalfordeling (forts.)

Matrisen  $\Sigma$  er symmetrisk (dvs.  $\sigma_{ij} = \sigma_{ji}$ ) og positiv semidefinit slik at  $|\Sigma| \geq 0$ . I eksemplene som følger antar vi at  $|\Sigma| > 0$ .

Dersom  $|\Sigma| = 0$  er fordelingen avgrenset til et underrom i det  $d$ -dimensjonale egenskapsrommet, noe som kan forekomme dersom egenskapene inneholder redundant informasjon (funksjonell kobling mellom egenskaper).

Komponenter i  $\Sigma$ :

$$\sigma_{ij, i \neq j} = E\{(x_i - \mu_i)(x_j - \mu_j)\} = \text{kovarians (ikke-diagonale komponenter),}$$

$$\sigma_{ii} = E\{(x_i - \mu_i)^2\} = \sigma_i^2 = \text{varians (diagonale komponenter).}$$



## Multivariat normalfordeling (forts.)


Hvis egenskapene  $x_i, x_j$ ,  $i \neq j$  er uavhengige medfører dette at

$$\sigma_{ij} = E\{(x_i - \mu_i)(x_j - \mu_j)\} = E\{x_i - \mu_i\}E\{x_j - \mu_j\} = 0 \cdot 0 = 0,$$

dvs.  $\Sigma$  er diagonal. Dette gir da

$$\begin{aligned} p(\mathbf{x}) &= \frac{1}{(2\pi)^{d/2} \prod_{i=1}^d \sigma_i} \exp \left\{ -\frac{1}{2} \sum_{i=1}^d \left( \frac{x_i - \mu_i}{\sigma_i} \right)^2 \right\} \\ &= \prod_{i=1}^d \frac{1}{\sqrt{2\pi} \sigma_i} \exp \left\{ -\frac{1}{2} \left( \frac{x_i - \mu_i}{\sigma_i} \right)^2 \right\} \\ &= \prod_{i=1}^d N(\mu_i, \sigma_i^2). \end{aligned}$$

## Multivariat normalfordeling (forts.)



Multivariat normalfordeling i to dimensjoner, dvs. *bivariat* normalfordeling.

# Mahalanobis avstand

Det kvadratiske uttrykket som inngår i eksponenten i den multivariate normalfordelingen, gitt ved størrelsen


$$r^2 = (\mathbf{x} - \boldsymbol{\mu})^t \boldsymbol{\Sigma}^{-1} (\mathbf{x} - \boldsymbol{\mu})$$

kalles gjerne den kvadrerte *Mahalanobis avstand*, dvs. et mål på avstand mellom forventningsverdien og et punkt  $\mathbf{x}$  i egenskapsrommet.

Konturer gjennom punkter med konstant sannsynlighetstetthet, og derved konstant  $r$ , danner hyperellipsoider omkring forventningsvektoren.

Volumet av disse hyperellipsoidene er et mål på spredningen av fordelingen.

## Mahalanobis avstand (forts.)



Bivariat normalfordeling representert ved ellipser med konstant tetthet (og konstant Mahalanobisavstand fra forventningsvektoren).

## Mahalanobis avstand (forts.)


Volumet for gitt Mahalanobisavstand  $r$  er gitt ved

$$V = V_d |\Sigma|^{1/2} r^d$$

der  $V_d$  = er volumet av en  $d$ -dimensjonal hyperkule med radius=1 (kan vises).

Spredningen av fordelingen er proporsjonal med  $|\Sigma|^{1/2}$  for gitt verdi av  $d$ .

Stort volum indikerer stor spredning, lite volum indikerer at fordelingen er tett konsentrert omkring forventningsvektoren.



# Innhold i kurset

- Introduksjon til mønstergjenkjenning
- [Beslutningsteori \(fortsetter neste gang\)](#)
- Parametriske metoder
- Ikke-parametriske metoder
- Lineære og generaliserte diskriminantfunksjoner
- Evaluering av klassifikatorer
- Ikke-ledet læring
- Klyngeanalyse.