

TEK5020/9020 Mønster-gjenkjenning Høsten 2023

Forelesning 6 – Parametriske metoder (3)

Idar Dyrdal (idar.dyrdal@its.uio.no)

UiO : Institutt for teknologisystemer

18. september 2023

Innhold i kurset

- Introduksjon til mønstergjenkjenning
- Beslutningsteori (desisjonsteori)
- Parametriske metoder (forts.)
- Ikke-parametriske metoder
- Lineære og generaliserte diskriminantfunksjoner
- Evaluering av klassifikatorer
- Ikke-ledet læring
- Klyngeanalyse.

Bayesisk estimering – oversikt

Tettheten i punkt \mathbf{x} er her gitt ved

$$p(\mathbf{x}|\mathcal{X}) = \int p(\mathbf{x}|\boldsymbol{\theta})p(\boldsymbol{\theta}|\mathcal{X})d\boldsymbol{\theta}$$

der $p(\boldsymbol{\theta}|\mathcal{X})$ er *a posteriori parameterfordeling* gitt ved

$$p(\boldsymbol{\theta}|\mathcal{X}) = \frac{p(\mathcal{X}|\boldsymbol{\theta})p(\boldsymbol{\theta})}{\int p(\mathcal{X}|\boldsymbol{\theta})p(\boldsymbol{\theta})d\boldsymbol{\theta}}.$$

Her er $p(\mathcal{X}|\boldsymbol{\theta})$ likelihoodfunksjonen som kan beregnes fra treningssettet ved

$$p(\mathcal{X}|\boldsymbol{\theta}) = \prod_{k=1}^n p(\mathbf{x}_k|\boldsymbol{\theta}),$$

der $p(\boldsymbol{\theta})$ (*a priori parameterfordeling*) og $p(\mathbf{x}|\boldsymbol{\theta})$ er kjente funksjoner av $\boldsymbol{\theta}$.

Bayesisk estimering av forventning i multivariat normalfordeling

Antar her følgende:

$$p(\mathbf{x}|\boldsymbol{\mu}) = N(\boldsymbol{\mu}, \Sigma), \quad \boldsymbol{\mu} = \text{ukjent}, \Sigma = \text{kjent},$$

$$p(\boldsymbol{\mu}) = N(\boldsymbol{\mu}_0, \Sigma_0), \quad \boldsymbol{\mu}_0 = \text{kjent}, \Sigma_0 = \text{kjent},$$

$$\mathcal{X} = \{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n\}, \quad \text{treningssett med } n \text{ sampler fra én og samme klasse.}$$

Dette gir likelihoodfunksjonen

$$p(\mathcal{X}|\boldsymbol{\mu}) = \prod_{k=1}^n p(\mathbf{x}_k|\boldsymbol{\mu}) = \frac{1}{(2\pi)^{nd/2} |\Sigma|^{n/2}} \prod_{k=1}^n \exp \left[-\frac{1}{2} (\mathbf{x}_k - \boldsymbol{\mu})^t \Sigma^{-1} (\mathbf{x}_k - \boldsymbol{\mu}) \right].$$

Bayesisk estimering av forventning i multivariat normalfordeling (forts.)

A posteriori parameterfordeling blir da

$$\begin{aligned}
 p(\boldsymbol{\mu}|\mathcal{X}) &= \frac{p(\mathcal{X}|\boldsymbol{\mu})p(\boldsymbol{\mu})}{\int p(\mathcal{X}|\boldsymbol{\mu})p(\boldsymbol{\mu})d\boldsymbol{\mu}} \\
 &= \alpha \exp \left[-\frac{1}{2} \sum_{k=1}^n (\mathbf{x}_k - \boldsymbol{\mu})^t \boldsymbol{\Sigma}^{-1} (\mathbf{x}_k - \boldsymbol{\mu}) \right] \exp \left[-\frac{1}{2} (\boldsymbol{\mu} - \boldsymbol{\mu}_0)^t \boldsymbol{\Sigma}_0^{-1} (\boldsymbol{\mu} - \boldsymbol{\mu}_0) \right] \\
 &= \alpha e^{-\frac{1}{2} \left[n\boldsymbol{\mu}^t \boldsymbol{\Sigma}^{-1} \boldsymbol{\mu} + \boldsymbol{\mu}^t \boldsymbol{\Sigma}_0^{-1} \boldsymbol{\mu} + \sum_{k=1}^n \mathbf{x}_k^t \boldsymbol{\Sigma}^{-1} \mathbf{x}_k - 2\boldsymbol{\mu}^t \boldsymbol{\Sigma}^{-1} \sum_{k=1}^n \mathbf{x}_k - 2\boldsymbol{\mu}_0^t \boldsymbol{\Sigma}_0^{-1} \boldsymbol{\mu} + \boldsymbol{\mu}_0^t \boldsymbol{\Sigma}_0^{-1} \boldsymbol{\mu}_0 \right]},
 \end{aligned}$$

der nevneren inngår i skalaren α .

Bayesisk estimering av forventning i multivariat normalfordeling (forts.)

Videre regning gir

$$p(\boldsymbol{\mu}|\mathcal{X}) =$$

$$= \alpha e^{-\frac{1}{2} \left\{ n\boldsymbol{\mu}^t \boldsymbol{\Sigma}^{-1} \boldsymbol{\mu} + \boldsymbol{\mu}^t \boldsymbol{\Sigma}_0^{-1} \boldsymbol{\mu} + \underbrace{\sum_{k=1}^n \mathbf{x}_k^t \boldsymbol{\Sigma}^{-1} \mathbf{x}_k}_{\text{strykes}} - 2\boldsymbol{\mu}^t \boldsymbol{\Sigma}^{-1} \sum_{k=1}^n \mathbf{x}_k - 2\boldsymbol{\mu}^t \boldsymbol{\Sigma}_0^{-1} \boldsymbol{\mu}_0 + \underbrace{\boldsymbol{\mu}_0^t \boldsymbol{\Sigma}_0^{-1} \boldsymbol{\mu}_0}_{\text{strykes}} \right\}}$$

$$= \alpha' \exp \left[-\frac{1}{2} \left\{ \boldsymbol{\mu}^t (n\boldsymbol{\Sigma}^{-1} + \boldsymbol{\Sigma}_0^{-1}) \boldsymbol{\mu} - 2\boldsymbol{\mu}^t (\boldsymbol{\Sigma}^{-1} \sum_{k=1}^n \mathbf{x}_k + \boldsymbol{\Sigma}_0^{-1} \boldsymbol{\mu}_0) \right\} \right]$$

$$= \alpha' \exp \left[-\frac{1}{2} \{ \boldsymbol{\mu}^t \boldsymbol{\Sigma}_n^{-1} \boldsymbol{\mu} - 2\boldsymbol{\mu}^t \boldsymbol{\Sigma}_n^{-1} \boldsymbol{\mu}_n \} \right].$$

Bayesisk estimering av forventning i multivariat normalfordeling (forts.)

Her er innført størrelsene $\boldsymbol{\mu}_n$ og Σ_n som er løsninger av likningssystemet

$$\Sigma_n^{-1} = n\Sigma^{-1} + \Sigma_0^{-1}$$

$$\Sigma_n^{-1} \boldsymbol{\mu}_n = n\Sigma^{-1} \mathbf{m}_n + \Sigma_0^{-1} \boldsymbol{\mu}_0,$$

$$\text{der } \mathbf{m}_n = \frac{1}{n} \sum_{k=1}^n \mathbf{x}_k.$$

Bayesisk estimering av forventning i multivariat normalfordeling (forts.)

A posteriori parameterfordeling kan da skrives som

$$\begin{aligned}
 p(\boldsymbol{\mu}|\mathcal{X}) &= \alpha'' \exp \left[-\frac{1}{2} \{ \boldsymbol{\mu}^t \Sigma_n^{-1} \boldsymbol{\mu} - 2 \boldsymbol{\mu}^t \Sigma_n^{-1} \boldsymbol{\mu}_n + \boldsymbol{\mu}_n^t \Sigma_n^{-1} \boldsymbol{\mu}_n \} \right] \\
 &= \alpha'' \exp \left[-\frac{1}{2} (\boldsymbol{\mu} - \boldsymbol{\mu}_n)^t \Sigma_n^{-1} (\boldsymbol{\mu} - \boldsymbol{\mu}_n) \right] \\
 &= \underline{\underline{N(\boldsymbol{\mu}_n, \Sigma_n)}},
 \end{aligned}$$

dvs. en multivariat normalfordeling med $\boldsymbol{\mu}_n$ og Σ_n gitt av likningssystemet

$$\Sigma_n^{-1} = n\Sigma^{-1} + \Sigma_0^{-1} \quad (I)$$

$$\Sigma_n^{-1} \boldsymbol{\mu}_n = n\Sigma^{-1} \boldsymbol{m}_n + \Sigma_0^{-1} \boldsymbol{\mu}_0. \quad (II)$$

Bayesisk estimering av forventning i multivariat normalfordeling (forts.)

Fra likning (I) får man

$$\Sigma_n = \left[\left(\frac{1}{n} \Sigma \right)^{-1} + \Sigma_0^{-1} \right]^{-1} = \frac{1}{n} \Sigma \left(\frac{1}{n} \Sigma + \Sigma_0 \right)^{-1} \Sigma_0 = \frac{1}{n} \Sigma_0 \left(\frac{1}{n} \Sigma + \Sigma_0 \right)^{-1} \Sigma$$

der relasjonene

$$(A^{-1} + B^{-1})^{-1} = A(A+B)^{-1}B = B(A+B)^{-1}A,$$

er benyttet. Her er A og B er ikke-singulære, kvadratiske matriser. Ved å løse for Σ_n fra (I) og sette inn i (II), får man

$$\begin{aligned} \boldsymbol{\mu}_n &= n \Sigma_n \Sigma^{-1} \mathbf{m}_n + \Sigma_n \Sigma_0^{-1} \boldsymbol{\mu}_0 \\ &= \Sigma_0 \left(\frac{1}{n} \Sigma + \Sigma_0 \right)^{-1} \Sigma \Sigma^{-1} \mathbf{m}_n + \frac{1}{n} \Sigma \left(\frac{1}{n} \Sigma + \Sigma_0 \right)^{-1} \Sigma_0 \Sigma_0^{-1} \boldsymbol{\mu}_0 \\ &= \Sigma_0 \left(\frac{1}{n} \Sigma + \Sigma_0 \right)^{-1} \mathbf{m}_n + \frac{1}{n} \Sigma \left(\frac{1}{n} \Sigma + \Sigma_0 \right)^{-1} \boldsymbol{\mu}_0 \\ &= C_1 \mathbf{m}_n + C_2 \boldsymbol{\mu}_0 \\ &= \underline{\underline{\text{veiet middel av } \mathbf{m}_n \text{ og } \boldsymbol{\mu}_0.}} \end{aligned}$$

Bayesisk estimering av forventning i multivariat normalfordeling (forts.)

Her er

$$\begin{aligned}C_1 + C_2 &= \Sigma_0 \left(\frac{1}{n} \Sigma + \Sigma_0 \right)^{-1} + \frac{1}{n} \Sigma \left(\frac{1}{n} \Sigma + \Sigma_0 \right)^{-1} \\&= \left(\Sigma_0 + \frac{1}{n} \Sigma \right) \left(\frac{1}{n} \Sigma + \Sigma_0 \right)^{-1} \\&= I.\end{aligned}$$

I grensen $n \rightarrow \infty$ (det asymptotiske tilfellet) får man da

$$\begin{aligned}\boldsymbol{\mu}_n &\rightarrow \boldsymbol{m}_n \\ \Sigma_n &\rightarrow \frac{1}{n} \Sigma \rightarrow 0,\end{aligned}$$

dvs. Bayes løsning \rightarrow maksimum likelihood løsningen når n vokser.

Bayesisk estimering av forventning i multivariat normalfordeling (forts.)


Tettheten i punktet \mathbf{x} blir da

$$\begin{aligned} p(\mathbf{x}|\mathcal{X}) &= \int p(\mathbf{x}|\boldsymbol{\mu})p(\boldsymbol{\mu}|\mathcal{X})d\boldsymbol{\mu} \\ &= \int N(\boldsymbol{\mu}, \Sigma) \times N(\boldsymbol{\mu}_n, \Sigma_n) \\ &= \underline{\underline{N(\boldsymbol{\mu}_n, \Sigma + \Sigma_n)}} \quad (\text{kan vises}). \end{aligned}$$

Den kjente kovariansmatrisen Σ har altså fått et tillegg Σ_n som representerer usikkerheten i estimatet av forventningen.

Asymptotisk blir $p(\mathbf{x}|\mathcal{X}) = N(\mathbf{m}_n, \Sigma)$.

Estimering av forventningsvektor i bivariat normalfordeling (Eksempel)



To egenskaper x_1 og x_2

- Datasett med 100 objekter, trukket fra normalfordeling med

$$\boldsymbol{\mu} = \begin{bmatrix} 2 \\ 3 \end{bmatrix} \text{ og } \Sigma = \begin{bmatrix} 1 & 1,5 \\ 1,5 & 3 \end{bmatrix}.$$

- Antar bivariat normalfordeling med ukjent $\boldsymbol{\mu}$ og kjent Σ .
- Skal finne a posteriori parameterfordeling, $\boldsymbol{\mu}_n$ og Σ_n som funksjon av antall sampler n i treningssettet.

Estimering av forventningsvektor i bivariat normalfordeling (forts.)

La her ukjent tetthetsfunksjon og a priori parameterfordeling være hhv.

$p(\mathbf{x}|\boldsymbol{\mu}) = N(\boldsymbol{\mu}, \Sigma)$ der Σ antas kjent og $\boldsymbol{\mu}$ er ukjent, og

$p(\boldsymbol{\mu}) = N(\boldsymbol{\mu}_0, \Sigma_0)$ der $\boldsymbol{\mu}_0$ og Σ_0 er kjente.

A posteriori parameterfordeling blir da

$$p(\boldsymbol{\mu}|\mathcal{X}) = N(\boldsymbol{\mu}_n, \Sigma_n).$$

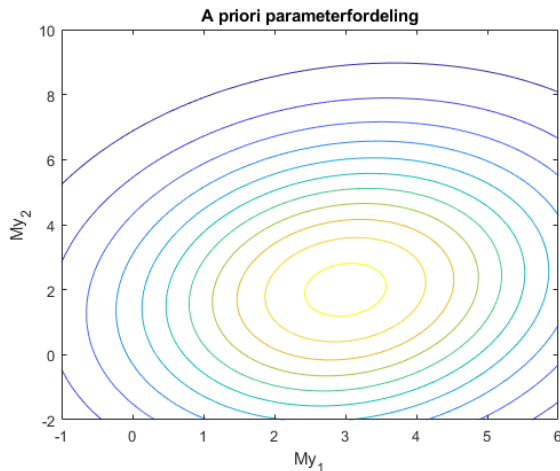
Her er estimatene av forventning og varians

$$\boldsymbol{\mu}_n = n\Sigma_n\Sigma^{-1}\mathbf{m}_n + \Sigma_n\Sigma_0^{-1}\boldsymbol{\mu}_0 \quad \text{og} \quad \Sigma_n = \left[\left(\frac{1}{n}\Sigma \right)^{-1} + \Sigma_0^{-1} \right]^{-1},$$

der \mathbf{m}_n er sampelmiddelet over treningssettet. Skal ut fra dette beregne det Bayesiske tetthetsestimatet

$$p(\mathbf{x}|\mathcal{X}) = N(\boldsymbol{\mu}_n, \Sigma + \Sigma_n).$$

Estimering av forventningsvektor til bivariat normalfordeling (forts.)




- A priori parameterfordeling $N(\boldsymbol{\mu}_0, \Sigma_0)$ der

$$\boldsymbol{\mu}_0 = \begin{bmatrix} 3 \\ 2 \end{bmatrix} \text{ og } \Sigma_0 = \begin{bmatrix} 5 & 1 \\ 1 & 10 \end{bmatrix}.$$


- Her er $\boldsymbol{\mu}_0$ beste gjetning om forventningsvektoren.
- Σ_0 representerer usikkerheten om denne gjetningen.

Estimering av forventningsvektor til bivariat normalfordeling (forts.)



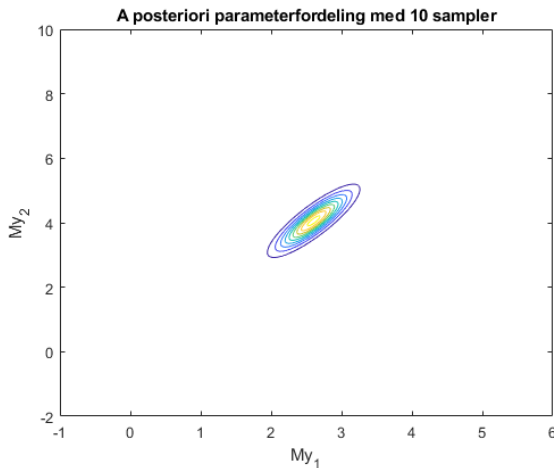
A posteriori parameterfordeling $p(\boldsymbol{\mu}|\mathcal{X}^1)$. Maksimum for $\boldsymbol{\mu} = [2.37, 4.11]^t$.

Estimering av forventningsvektor til bivariat normalfordeling (forts.)




A posteriori parameterfordeling $p(\boldsymbol{\mu}|\mathcal{X}^5)$. Maksimum for $\boldsymbol{\mu} = [2.25, 3.32]^t$.

Estimering av forventningsvektor til bivariat normalfordeling (forts.)




A posteriori parameterfordeling $p(\boldsymbol{\mu} | \mathcal{X}^{10})$. Maksimum for $\boldsymbol{\mu} = [2.60, 4.05]^t$.

Estimering av forventningsvektor til bivariat normalfordeling (forts.)




A posteriori parameterfordeling $p(\boldsymbol{\mu} | \mathcal{X}^{20})$. Maksimum for $\boldsymbol{\mu} = [2.65, 3.90]^t$.

Estimering av forventningsvektor til bivariat normalfordeling (forts.)



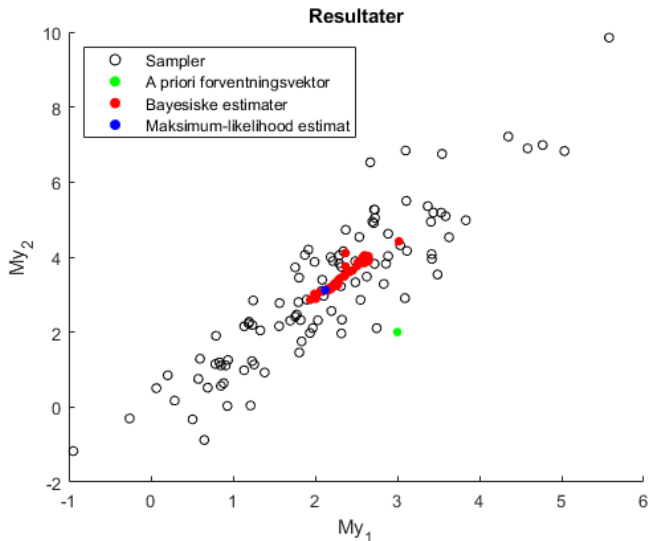
A posteriori parameterfordeling $p(\boldsymbol{\mu} | \mathcal{X}^{50})$. Maksimum for $\boldsymbol{\mu} = [2.28, 3.28]^t$.

Estimering av forventningsvektor til bivariat normalfordeling (forts.)



A posteriori parameterfordeling $p(\boldsymbol{\mu} | \mathcal{X}^{100})$. Maksimum for $\boldsymbol{\mu} = [2.12, 3.12]^t$.

Estimering av forventningsvektor til bivariat normalfordeling (forts.)



Estimering av forventningsvektor i bivariat normalfordeling (forts.)

Estimatet av kovariansmatrisen Σ_n for $n = 100$ blir her

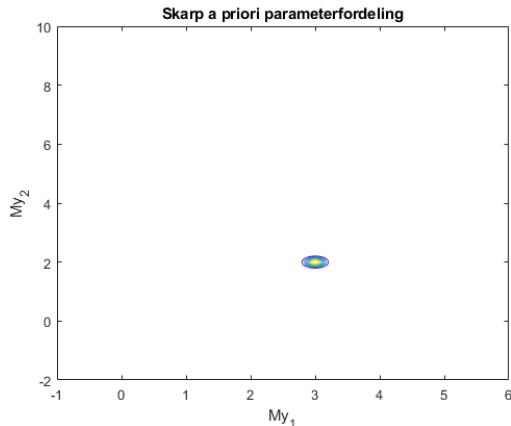
$$\begin{aligned}\Sigma_n &= \left\{ \left(\frac{1}{n} \Sigma \right)^{-1} + \Sigma_0^{-1} \right\}^{-1} \\&= \left\{ \left(\frac{1}{100} \begin{bmatrix} 1 & 1,5 \\ 1,5 & 3 \end{bmatrix} \right)^{-1} + \begin{bmatrix} 5 & 1 \\ 1 & 10 \end{bmatrix}^{-1} \right\}^{-1} \\&= \left\{ \begin{bmatrix} 400 & -200 \\ -200 & 1,3333 \end{bmatrix} + \begin{bmatrix} 0.204082 & -0.020408 \\ -0.020408 & 0.102041 \end{bmatrix} \right\}^{-1} \\&= \underline{\underline{\frac{1}{1000} \begin{bmatrix} 9,9629 & 14,934 \\ 14,934 & 29,881 \end{bmatrix}}}\end{aligned}$$

Estimering av forventningsvektor i bivariat normalfordeling (forts.)

Forventningsestimatet $\boldsymbol{\mu}_n$ for $n = 100$ blir tilsvarende

$$\begin{aligned}
 \boldsymbol{\mu}_n &= n \boldsymbol{\Sigma}_n \boldsymbol{\Sigma}_n^{-1} \mathbf{m}_n + \boldsymbol{\Sigma}_n \boldsymbol{\Sigma}_0^{-1} \boldsymbol{\mu}_0 \\
 &= \frac{1}{10} \begin{bmatrix} 9,9629 & 14,934 \\ 14,934 & 29,881 \end{bmatrix} \begin{bmatrix} 1 & 1,5 \\ 1,5 & 3 \end{bmatrix}^{-1} \mathbf{m}_n + \frac{1}{10} \begin{bmatrix} 9,9629 & 14,934 \\ 14,934 & 29,881 \end{bmatrix} \begin{bmatrix} 5 & 1 \\ 1 & 10 \end{bmatrix}^{-1} \boldsymbol{\mu}_0 \\
 &= \begin{bmatrix} 0,99827 & -0,00132 \\ -0,00244 & 0,99726 \end{bmatrix} \begin{bmatrix} 2,1231 \\ 3,1217 \end{bmatrix} + \frac{1}{1000} \begin{bmatrix} 1,7285 & 1,3206 \\ 2,4380 & 2,7443 \end{bmatrix} \begin{bmatrix} 3 \\ 2 \end{bmatrix} \\
 &= \underline{\underline{\begin{bmatrix} 2,1231 \\ 3,1207 \end{bmatrix}}}
 \end{aligned}$$

Estimering av forventningsvektor til bivariat normalfordeling (forts.)



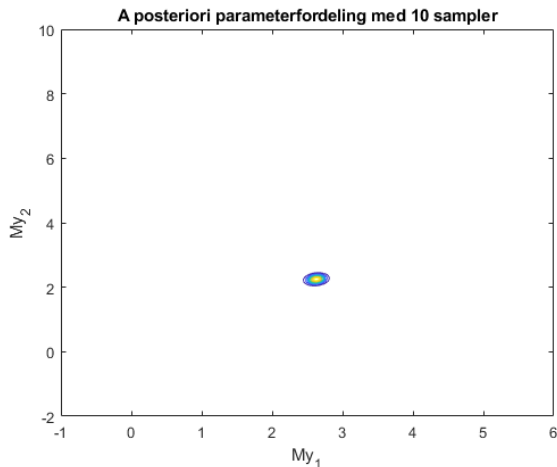
La nå a priori parameterfordeling være gitt ved $N(\boldsymbol{\mu}_0, \boldsymbol{\Sigma}_0)$ med

$$\boldsymbol{\mu}_0 = \begin{bmatrix} 3 \\ 2 \end{bmatrix}$$

og

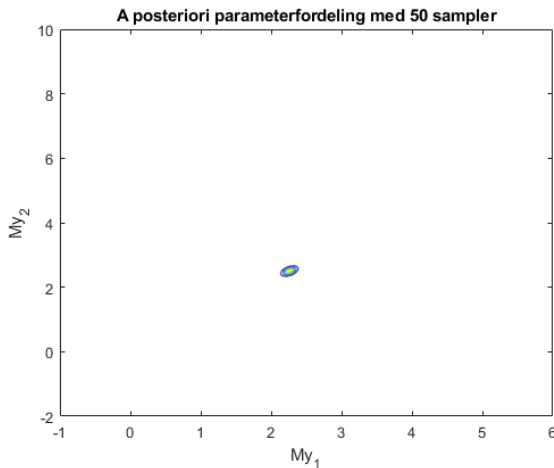
$$\boldsymbol{\Sigma}_0 = \begin{bmatrix} 0,01 & 0 \\ 0 & 0,01 \end{bmatrix}.$$

Estimering av forventningsvektor til bivariat normalfordeling (forts.)




A posteriori parameterfordeling $p(\boldsymbol{\mu} | \mathcal{X}^{10})$. Maksimum for $\boldsymbol{\mu} = [2.63, 2.25]^t$.

Estimering av forventningsvektor til bivariat normalfordeling (forts.)




A posteriori parameterfordeling $p(\boldsymbol{\mu}|\mathcal{X}^{50})$. Maksimum for $\boldsymbol{\mu} = [2.26, 2.50]^t$.

Estimering av forventningsvektor til bivariat normalfordeling (forts.)



A posteriori parameterfordeling $p(\boldsymbol{\mu} | \mathcal{X}^{100})$. Maksimum for $\boldsymbol{\mu} = [2.10, 2.62]^t$.

Estimering av forventningsvektor til bivariat normalfordeling (forts.)



Estimering av forventningsvektor i bivariat normalfordeling (forts.)

Estimatet av kovariansmatrisen Σ_n for $n = 100$ blir her

$$\begin{aligned}\Sigma_n &= \left\{ \left(\frac{1}{n} \Sigma \right)^{-1} + \Sigma_0^{-1} \right\}^{-1} \\&= \left\{ \left(\frac{1}{100} \begin{bmatrix} 1 & 1,5 \\ 1,5 & 3 \end{bmatrix} \right)^{-1} + \begin{bmatrix} 0,01 & 0 \\ 0 & 0,01 \end{bmatrix}^{-1} \right\}^{-1} \\&= \left\{ \begin{bmatrix} 400 & -200 \\ -200 & 1,3333 \end{bmatrix} + \begin{bmatrix} 100 & 0 \\ 0 & 100 \end{bmatrix} \right\}^{-1} \\&= \underline{\underline{\frac{1}{1000} \begin{bmatrix} 3,0435 & 2,6087 \\ 2,6087 & 6,5217 \end{bmatrix}}}\end{aligned}$$

Estimering av forventningsvektor i bivariat normalfordeling (forts.)

Forventningsestimatet $\boldsymbol{\mu}_n$ for $n = 100$ blir tilsvarende

$$\boldsymbol{\mu}_n = n\Sigma_n\Sigma^{-1}\mathbf{m}_n + \Sigma_n\Sigma_0^{-1}\boldsymbol{\mu}_0$$

$$= \frac{1}{10} \begin{bmatrix} 3,0435 & 2,6087 \\ 2,6087 & 6,5217 \end{bmatrix} \begin{bmatrix} 1 & 1,5 \\ 1,5 & 3 \end{bmatrix}^{-1} \mathbf{m}_n + \frac{1}{1000} \begin{bmatrix} 3,0435 & 2,6087 \\ 2,6087 & 6,5217 \end{bmatrix} \begin{bmatrix} 0,01 & 0 \\ 0 & 0,01 \end{bmatrix}^{-1} \boldsymbol{\mu}_0$$

$$= \begin{bmatrix} 0,6957 & -0,2609 \\ -0,2609 & 0,3478 \end{bmatrix} \begin{bmatrix} 2,1231 \\ 3,1217 \end{bmatrix} + \begin{bmatrix} 0,30435 & 0,26087 \\ 0,26087 & 0,65217 \end{bmatrix} \begin{bmatrix} 3 \\ 2 \end{bmatrix}$$

$$= \underline{\underline{\begin{bmatrix} 2,0974 \\ 2,6189 \end{bmatrix}}}$$

Suffisiente observatorer

Vi har sett at Bayesisk estimering gir kompliserte beregninger selv i enkle tilfeller.

Eksistensen av såkalte *suffisiente observatorer*, f.eks.

$$\mathbf{m}_n = \frac{1}{n} \sum_{k=1}^n \mathbf{x}_k$$

for den multivariate normalfordelingen $N(\boldsymbol{\mu}_n, \Sigma_n)$, gir mulighet til forenklinger.

Observatoren inneholder den informasjon fra treningssettet \mathcal{X} som er *tilstrekkelig* for estimering av parametervektoren $\boldsymbol{\theta}$.

Suffisiente observatorer (forts.)

Definisjon:

\mathbf{s} er suffisient for $\boldsymbol{\theta}$ hvis $p(\boldsymbol{\theta}|\mathbf{s})$ er uavhengig av $\boldsymbol{\theta}$, dvs. hvis

$$p(\mathcal{X}|\mathbf{s}, \boldsymbol{\theta}) = p(\mathcal{X}|\mathbf{s}).$$

Innsatt i Bayes formel gir dette (med $\boldsymbol{\theta}$ antatt stokastisk)

$$p(\boldsymbol{\theta}|\mathbf{s}, \mathcal{X}) = \frac{p(\mathcal{X}|\mathbf{s}, \boldsymbol{\theta})p(\boldsymbol{\theta}|\mathbf{s})}{p(\mathcal{X}|\mathbf{s})} = p(\boldsymbol{\theta}|\mathbf{s}).$$

Suffisiente observatorer (forts.)

Dette gir

$$\mathbf{s} \text{ suffisient} \quad \Rightarrow \quad p(\boldsymbol{\theta}|\mathbf{s}, \mathcal{X}) = p(\boldsymbol{\theta}|\mathbf{s}),$$

(der ekvivalens kan vises) slik at \mathbf{s} inneholder all nødvendig informasjon fra \mathcal{X} .

Det kan også vises at

$$\mathbf{s} \text{ er suffisient for } \boldsymbol{\theta} \text{ hvis og bare hvis } p(\mathcal{X}|\boldsymbol{\theta}) = g(\mathbf{s}, \boldsymbol{\theta})h(\mathcal{X}),$$

(det såkalte *faktoriseringsteoremet*).

Suffisiente observatorer er nyttige dersom \mathbf{s} og $g(\mathbf{s}, \boldsymbol{\theta})$ er enkle og mest mulig av likelihoodfunksjonen kan skilles ut i faktoren $h(\mathcal{X})$.

Suffisiente observatorer (forts.)

Bruk av suffisiente observatorer

1) Maksimum likelihood estimering:

Her skal likelihoodfunksjonen

$$p(\mathcal{X}|\boldsymbol{\theta}) = g(\mathbf{s}, \boldsymbol{\theta})h(\mathcal{X})$$

maksimaliseres med hensyn på parametervektoren $\boldsymbol{\theta}$.

Det er tilstrekkelig å finne maksimum av funksjonen

$$g(\mathbf{s}, \boldsymbol{\theta}),$$

(en kjent funksjon så snart \mathbf{s} er beregnet fra treningssettet) med hensyn på $\boldsymbol{\theta}$, og glemme $h(\mathcal{X})$.

Suffisiente observatorer (forts.)

Bruk av suffisiente observatorer

2) Bayesisk estimering:

Her må man først finne a posteriori parameterfordeling fra uttrykket

$$\begin{aligned} p(\boldsymbol{\theta}|\mathcal{X}) &= \frac{p(\mathcal{X}|\boldsymbol{\theta})p(\boldsymbol{\theta})}{\int p(\mathcal{X}|\boldsymbol{\theta})p(\boldsymbol{\theta})d\boldsymbol{\theta}} \\ &= \frac{g(\mathbf{s},\boldsymbol{\theta})h(\mathcal{X})p(\boldsymbol{\theta})}{\int g(\mathbf{s},\boldsymbol{\theta})h(\mathcal{X})p(\boldsymbol{\theta})d\boldsymbol{\theta}} \quad (\text{faktoren } h(\mathcal{X}) \text{ kan her strykes oppe og nede}) \\ &= \frac{g(\mathbf{s},\boldsymbol{\theta})p(\boldsymbol{\theta})}{\int g(\mathbf{s},\boldsymbol{\theta})p(\boldsymbol{\theta})d\boldsymbol{\theta}}. \end{aligned}$$

Suffisiente observatorer (forts.)

Dersom $p(\boldsymbol{\theta})$ er uniform kan denne fordelingen uttrykkes ved

$$p(\boldsymbol{\theta}|\mathcal{X}) = \frac{g(\mathbf{s}, \boldsymbol{\theta})}{\int g(\mathbf{s}, \boldsymbol{\theta}) d\boldsymbol{\theta}} = \tilde{g}(\mathbf{s}, \boldsymbol{\theta}),$$

den såkalte *kjernetettheten* til g . Kjernetettheten er invariant under skalering av g .

Resultatet ovenfor gjelder også i det asymptotiske tilfellet selv om $p(\boldsymbol{\theta})$ *ikke* er uniform.

Dersom $n \gg 1$ vil $p(\boldsymbol{\theta}|\mathcal{X}) \approx \tilde{g}(\mathbf{s}, \boldsymbol{\theta})$ selv om $p(\boldsymbol{\theta})$ ikke er uniform. I dette tilfellet blir

$$p(\mathbf{x}|\mathcal{X}) \approx \int p(\mathbf{x}|\boldsymbol{\theta}) \tilde{g}(\mathbf{s}, \boldsymbol{\theta}) d\boldsymbol{\theta}$$

der $p(\mathbf{x}|\boldsymbol{\theta})$ er antatt kjent (som funksjon av \mathbf{x} og $\boldsymbol{\theta}$), mens \tilde{g} kan finnes i lærebøker.

Ekspensialfamilien

Familie av fordelinger med enkle suffisiente observatorer og faktoriseringer (enkle g eller \tilde{g} funksjoner) på formen

$$p(\mathbf{x} | \boldsymbol{\theta}) = \alpha(\mathbf{x}) \exp[a(\boldsymbol{\theta}) + \mathbf{b}(\boldsymbol{\theta})^t \mathbf{c}(\mathbf{x})],$$

der a er en skalar og \mathbf{b} og \mathbf{c} er vektorer. Likelihoodfunksjonen kan da skrives som

$$\begin{aligned} p(\mathcal{X} | \boldsymbol{\theta}) &= \prod_{k=1}^n \alpha(\mathbf{x}_k) \exp[a(\boldsymbol{\theta}) + \mathbf{b}(\boldsymbol{\theta})^t \mathbf{c}(\mathbf{x}_k)] \\ &= \underbrace{\exp \left[n \left\{ a(\boldsymbol{\theta}) + \mathbf{b}(\boldsymbol{\theta})^t \frac{1}{n} \sum_{k=1}^n \mathbf{c}(\mathbf{x}_k) \right\} \right]}_{g(\mathbf{s}, \boldsymbol{\theta})} \underbrace{\prod_{k=1}^n \alpha(\mathbf{x}_k)}_{h(\mathcal{X})} \\ &= g(\mathbf{s}, \boldsymbol{\theta}) h(\mathcal{X}), \end{aligned}$$

der den suffisiente observatoren er gitt ved $\mathbf{s} = \frac{1}{n} \sum_{k=1}^n \mathbf{c}(\mathbf{x}_k)$.

Eksempel – Univariat normalfordeling

Her er

$$\boldsymbol{\theta} = \begin{bmatrix} \mu \\ \sigma^2 \end{bmatrix}, \alpha(x) = \frac{1}{\sqrt{2\pi}}, a(\boldsymbol{\theta}) = -\frac{\mu^2}{2\sigma^2} - \ln \sigma, \mathbf{b}(\boldsymbol{\theta}) = \begin{bmatrix} \frac{\mu}{\sigma^2} \\ -\frac{1}{2\sigma^2} \end{bmatrix} \text{ og } \mathbf{c}(x) = \begin{bmatrix} x \\ x^2 \end{bmatrix},$$

som gir

$$\begin{aligned} p(x|\boldsymbol{\theta}) &= \frac{1}{\sqrt{2\pi}} \exp \left\{ -\frac{\mu^2}{2\sigma^2} - \ln \sigma + \begin{bmatrix} \frac{\mu}{\sigma^2} \\ -\frac{1}{2\sigma^2} \end{bmatrix}^t \begin{bmatrix} x \\ x^2 \end{bmatrix} \right\} \\ &= \frac{1}{\sqrt{2\pi}\sigma} \exp \left\{ -\frac{x^2 - 2\mu x + \mu^2}{2\sigma^2} \right\} \\ &= \frac{1}{\sqrt{2\pi}\sigma} \exp \left\{ -\frac{(x - \mu)^2}{2\sigma^2} \right\} = \underline{\underline{N(\mu, \sigma^2)}}. \end{aligned}$$

Eksempel – Multivariat normalfordeling

Her er

$$\boldsymbol{\theta} = \begin{bmatrix} \boldsymbol{\mu} \\ \Sigma \end{bmatrix}, \alpha(\mathbf{x}) = \frac{1}{(2\pi)^{\frac{d}{2}}}, a(\boldsymbol{\theta}) = -\frac{1}{2}\boldsymbol{\mu}^t \Sigma^{-1} \boldsymbol{\mu} - \frac{1}{2} \ln |\Sigma|, \mathbf{b}(\boldsymbol{\theta}) = \begin{bmatrix} \Sigma^{-1} \boldsymbol{\mu} \\ -\frac{1}{2} \Sigma^{-1} \end{bmatrix} \text{ og } \mathbf{c}(\mathbf{x}) = \begin{bmatrix} \mathbf{x} \\ \mathbf{x} \mathbf{x}^t \end{bmatrix},$$

som gir

$$\begin{aligned} p(\mathbf{x} | \boldsymbol{\theta}) &= \frac{1}{(2\pi)^{\frac{d}{2}}} \exp \left\{ -\frac{1}{2} \boldsymbol{\mu}^t \Sigma^{-1} \boldsymbol{\mu} - \frac{1}{2} \ln |\Sigma| + \begin{bmatrix} \Sigma^{-1} \boldsymbol{\mu} \\ -\frac{1}{2} \Sigma^{-1} \end{bmatrix}^t \begin{bmatrix} \mathbf{x} \\ \mathbf{x} \mathbf{x}^t \end{bmatrix} \right\} \\ &= \frac{1}{(2\pi)^{\frac{d}{2}} |\Sigma|^{\frac{1}{2}}} \exp \left\{ -\frac{1}{2} \boldsymbol{\mu}^t \Sigma^{-1} \boldsymbol{\mu} + \boldsymbol{\mu}^t \Sigma^{-1} \mathbf{x} - \frac{1}{2} \underbrace{(\Sigma^{-1} : \mathbf{x} \mathbf{x}^t)}_{\text{Frobeniusprodukt}} \right\} \\ &= \frac{1}{(2\pi)^{\frac{d}{2}} |\Sigma|^{\frac{1}{2}}} \exp \left\{ -\frac{1}{2} \boldsymbol{\mu}^t \Sigma^{-1} \boldsymbol{\mu} + \boldsymbol{\mu}^t \Sigma^{-1} \mathbf{x} - \frac{1}{2} \mathbf{x}^t \Sigma^{-1} \mathbf{x} \right\} \text{ (siden } \Sigma^{-1} : \mathbf{x} \mathbf{x}^t = \mathbf{x}^t \Sigma^{-1} \mathbf{x}) \\ &= \frac{1}{(2\pi)^{\frac{d}{2}} |\Sigma|^{\frac{1}{2}}} \exp \left\{ -\frac{1}{2} (\mathbf{x} - \boldsymbol{\mu})^t \Sigma^{-1} (\mathbf{x} - \boldsymbol{\mu}) \right\} = \underline{\underline{N(\boldsymbol{\mu}, \Sigma)}}. \end{aligned}$$

Eksponensialfamilien – noen eksempler på fordelinger


Navn	Fordeling	Parametre	Suffisient observator	$g(s, \theta)$
Univariat normal	$p(x \theta) = \sqrt{\frac{\theta_2}{2\pi}} e^{-\frac{1}{2}\theta_2(x-\theta_1)^2}$	$\theta_1 = \mu$ $\theta_2 = \sigma^{-2}, \sigma > 0$	$s_1 = \frac{1}{n} \sum_{k=1}^n x_k$ $s_2 = \frac{1}{n} \sum_{k=1}^n x_k^2$	$\theta_2^{n/2} e^{-\frac{n}{2}\theta_2(s_2 - 2\theta_1 s_1 + \theta_1^2)}$
Multivariat normal	$p(x \theta) = \frac{ \Theta_2 ^{\frac{1}{2}}}{(2\pi)^{d/2}} e^{-\frac{1}{2}(x-\theta_1)^t \Theta_2 (x-\theta_1)}$	$\theta_1 = \mu$ $\Theta_2 = \Sigma^{-1}, \Theta_2 > 0$	$s_1 = \frac{1}{n} \sum_{k=1}^n x_k$ $S_2 = \frac{1}{n} \sum_{k=1}^n x_k x_k^t$	$ \Theta_2 ^{n/2} e^{\frac{n}{2} [Tr(\Theta_2)s_2 - 2\theta_1^t \Theta_2 s_1 + \theta_1^t \Theta_2 \theta_1]}$
Eksponensial	$p(x \theta) = \begin{cases} \theta e^{-\theta x} & x \geq 0 \\ 0 & \text{ellers} \end{cases}$	$\theta > 0$	$s = \frac{1}{n} \sum_{k=1}^n x_k$	$\theta^n e^{-n\theta s}$
Gamma	$p(x \theta) = \begin{cases} \frac{\theta_2^{\theta_1+1}}{\Gamma(\theta_1+1)} x^{\theta_1} e^{-\theta_2 x} & x \geq 0 \\ 0 & \text{ellers} \end{cases}$	$\theta_1 > -1$ $\theta_2 > 0$	$s_1 = \left(\prod_{k=1}^n x_k \right)^{1/n}$ $s_2 = \frac{1}{n} \sum_{k=1}^n x_k$	$\left[\frac{\theta_2^{\theta_1+1}}{\Gamma(\theta_1+1)} s_1^{\theta_1} e^{-\theta_2 s_2} \right]^n$
Poisson	$P(x \theta) = \frac{\theta^x}{x!} e^{-\theta}, \text{ der } x = 0, 1, 2, \dots$	$\theta > 0$	$s = \frac{1}{n} \sum_{k=1}^n x_k$	$\theta^{ns} e^{-n\theta}$
Multinomial	$P(x \theta) = m! \prod_{i=1}^d \frac{\theta_i^{x_i}}{x_i!}, \text{ der } \begin{cases} x_i = 0, 1, \dots, m \\ \sum_{i=1}^d x_i = m \end{cases}$	$\theta_{i=1, \dots, d} \text{ der } \begin{cases} 0 < \theta_i < 1 \\ \sum_{i=1}^d \theta_i = 1 \end{cases}$	$s = \frac{1}{n} \sum_{k=1}^n x_k$	$\prod_{i=1}^d \theta_i^{ns_i}$

Begrensninger ved parametriske metoder


Parametriske metoder har visse begrensninger:

- Tetthetsfunksjonene har som oftest ukjent form slik at gal eller dårlig antakelse om formen gir suboptimalt resultat.
- De fleste kjente (enkle) fordelinger har bare én mode, slik at de passer dårlig til mange virkelige fordelinger med flere moder (multimodale fordelinger).
- Tetthetsfunksjonene kan være kjente, men beregningsmessig kompliserte; de kan f.eks. bestå av en blanding av unimodale komponenter.

Unimodal fordeling



Multimodal fordeling



Innhold i kurset

- Introduksjon til mønstergjenkjenning
- Beslutningsteori
- Parametriske metoder
- Ikke-parametriske metoder
- Lineære og generaliserte diskriminantfunksjoner
- Evaluering av klassifikatorer
- Ikke-ledet læring
- Klyngeanalyse.