

TEK5020/9020 – Mønstergjenkjenning Høsten 2023


Løsningsforslag – Øvingsoppgaver 2

Idar Dyrdal (idar.dyrdal@its.uio.no)


UiO : Institutt for teknologisystemer

23. august 2023

Oppgave 1a



Oppgave 1b



Oppgave 1c

Likelihoodfunksjonen blir her

$$p(\mathcal{X} \mid \theta) = \prod_{i=1}^n p(x_i \mid \theta) = \prod_{i=1}^n \theta e^{-\theta x_i} = \theta^n \prod_{i=1}^n e^{-\theta x_i}$$

slik at Log-likelihoodfunksjonen blir

$$\begin{aligned}\mathcal{L}(\theta) &= \ln p(\mathcal{X} \mid \theta) \\ &= n \ln \theta + \sum_{i=1}^n (-\theta x_i) \\ &= n \ln \theta - \theta \sum_{i=1}^n x_i.\end{aligned}$$

Oppgave 1c (forts.)

Den deriverte med hensyn til θ blir

$$\frac{d\mathcal{L}(\theta)}{d\theta} = \frac{n}{\theta} - \sum_{i=1}^n x_i,$$

som skal settes lik null for å finne maksimum av Log-likelihoodfunksjonen, slik at

$$\frac{n}{\theta} = \sum_{i=1}^n x_i.$$

Maksimum likelihood-estimatet av parameteren θ blir da

$$\hat{\theta} = \frac{n}{\sum_{i=1}^n x_i}.$$

Oppgave 2

Sannsynligheten for \mathbf{x} kan her skrives som

$$P(\mathbf{x} \mid \boldsymbol{\theta}) = \prod_{i=1}^d \theta_i^{x_i} (1 - \theta_i)^{1-x_i} \quad (\text{Bernoullifordelingen})$$

Likelihood-funksjonen blir da

$$P(\mathcal{X} \mid \boldsymbol{\theta}) = \prod_{k=1}^n P(\mathbf{x}_k \mid \boldsymbol{\theta}) = \prod_{k=1}^n \prod_{i=1}^d \theta_i^{x_{ik}} (1 - \theta_i)^{1-x_{ik}}$$

der treningssettet er

$$\mathcal{X} = \{\mathbf{x}_1, \dots, \mathbf{x}_n\}$$

og x_{ik} er komponent nr. i i treningsvektor \mathbf{x}_k .

Oppgave 2 (forts.)

Log-likelihoodfunksjonen blir da

$$\mathcal{L}(\boldsymbol{\theta}) = \ln P(\mathcal{X} \mid \boldsymbol{\theta}) = \sum_{k=1}^n \sum_{i=1}^d \{x_{ik} \ln \theta_i + (1 - x_{ik}) \ln (1 - \theta_i)\}$$

som gir

$$\frac{\partial \mathcal{L}(\boldsymbol{\theta})}{\partial \theta_j} = \sum_{k=1}^n \sum_{i=1}^d \left\{ x_{ik} \frac{\delta_{ij}}{\theta_i} - (1 - x_{ik}) \frac{\delta_{ij}}{1 - \theta_i} \right\} = 0 \quad \forall \theta_j,$$

$$\text{der } \delta_{ij} = \begin{cases} 1 & i = j \\ 0 & i \neq j \end{cases} \quad (\text{Kronecker delta})$$

Oppgave 2 (forts.)

Dette gir likningssystemet

$$\sum_{k=1}^n \left\{ \frac{x_{jk}}{\theta_j} - \frac{1 - x_{jk}}{1 - \theta_j} \right\} = 0, \quad j = 1, \dots, d$$

slik at

$$\hat{\theta}_j = \frac{1}{n} \sum_{k=1}^n x_{jk}$$

og derav

$$\underline{\underline{\hat{\boldsymbol{\theta}} = \frac{1}{n} \sum_{k=1}^n \mathbf{x}_k,}}$$

hvilket skulle bevises.

Oppgave 3

Denne oppgaven går ut på å finne maksimum-likelihood estimatet av kovariansmatrisen i den multivariate normalfordelingen. Her er altså

$$p(\mathbf{x}|\Sigma) \sim N(\boldsymbol{\mu}, \Sigma),$$

der $\boldsymbol{\mu}$ er kjent og Σ er ukjent, og vi skal vise at maksimum-likelihood estimatet for Σ er gitt ved

$$\hat{\Sigma} = \frac{1}{n} \sum_{k=1}^n (\mathbf{x}_k - \boldsymbol{\mu})(\mathbf{x}_k - \boldsymbol{\mu})^t.$$

Dette gjøres i flere trinn i de følgende deloppgavene.

Oppgave 3a

Første trinn i utledningen er å bevise matriseidentiteten $\mathbf{a}^t \mathbf{A} \mathbf{a} = \text{Tr}\{\mathbf{A} \mathbf{a} \mathbf{a}^t\}$, der \mathbf{a} er en vektor og \mathbf{A} er en kvadratisk matrise. Venstre side kan skrives på komponentform som

$$\mathbf{a}^t \mathbf{A} \mathbf{a} = \sum_i a_i \left(\sum_j A_{ij} a_j \right) = \sum_{ij} a_i A_{ij} a_j = \sum_{ij} A_{ij} a_i a_j.$$

Hvert element i matrisen $\mathbf{A} \mathbf{a} \mathbf{a}^t$ på høyre side kan skrives som

$$\{\mathbf{A} \mathbf{a} \mathbf{a}^t\}_{ij} = \sum_k A_{ik} a_k a_j,$$

som ved innsetting i høyre side gir

$$\text{Tr}\{\mathbf{A} \mathbf{a} \mathbf{a}^t\} = \sum_l \{\mathbf{A} \mathbf{a} \mathbf{a}^t\}_{i=j=l} = \sum_l \sum_k A_{lk} a_k a_l = \sum_{lk} A_{lk} a_l a_k.$$

Dette viser at de to sidene er identiske, slik at $\mathbf{a}^t \mathbf{A} \mathbf{a} = \text{Tr}\{\mathbf{A} \mathbf{a} \mathbf{a}^t\}$, hvilket skulle bevises.

Oppgave 3b

Her skal likelihoodfunksjonen omskrives ved hjelp av identiteten i første deloppgave, slik at den blir

$$\begin{aligned}
 p(\mathcal{X} \mid \Sigma) &= p(\mathbf{x}_1, \dots, \mathbf{x}_n \mid \Sigma) \\
 &= \prod_{k=1}^n \frac{1}{(2\pi)^{\frac{d}{2}} |\Sigma|^{\frac{1}{2}}} e^{-\frac{1}{2}(\mathbf{x}_k - \boldsymbol{\mu})^t \Sigma^{-1}(\mathbf{x}_k - \boldsymbol{\mu})} \\
 &= \frac{1}{(2\pi)^{\frac{nd}{2}}} |\Sigma^{-1}|^{\frac{n}{2}} e^{-\frac{1}{2} \sum_{k=1}^n (\mathbf{x}_k - \boldsymbol{\mu})^t \Sigma^{-1}(\mathbf{x}_k - \boldsymbol{\mu})} \quad \left(\text{siden } |\Sigma| = \frac{1}{|\Sigma^{-1}|} \right) \\
 &= \frac{1}{(2\pi)^{\frac{nd}{2}}} |\Sigma^{-1}|^{\frac{n}{2}} e^{-\frac{1}{2} \sum_{k=1}^n \text{Tr}\{\Sigma^{-1}(\mathbf{x}_k - \boldsymbol{\mu})(\mathbf{x}_k - \boldsymbol{\mu})^t\}} \quad (\text{Se deloppgave a}) \\
 &= \frac{1}{(2\pi)^{\frac{nd}{2}}} |\Sigma^{-1}|^{\frac{n}{2}} e^{-\frac{1}{2} \text{Tr}\{\Sigma^{-1} \sum_{k=1}^n (\mathbf{x}_k - \boldsymbol{\mu})(\mathbf{x}_k - \boldsymbol{\mu})^t\}}, \quad \text{hvilket skulle bevises.}
 \end{aligned}$$

Oppgave 3c

Her kan vi definere en matrise A der

$$A = \Sigma^{-1} \hat{\Sigma} \quad \text{der} \quad \hat{\Sigma} = \frac{1}{n} \sum_{k=1}^n (\mathbf{x}_k - \boldsymbol{\mu})(\mathbf{x}_k - \boldsymbol{\mu})^t.$$

Eigenverdiene til A er gitt ved $A\mathbf{e}_i = \lambda_i \mathbf{e}_i$, $i = 1, \dots, d$, slik at

$$|A| = \prod_{i=1}^d \lambda_i \quad \text{og} \quad \text{Tr } A = \sum_{i=1}^d \lambda_i \quad (\text{kan vises}).$$

Likelihoodfunksjonen kan derved skrives som

$$p(\mathbf{x}_1, \dots, \mathbf{x}_n | \Sigma) = \frac{1}{(2\pi)^{\frac{nd}{2}}} \left(\frac{|A|}{|\hat{\Sigma}|} \right)^{\frac{n}{2}} e^{-\frac{n}{2} \text{Tr } A} = \frac{(\prod_{i=1}^d \lambda_i)^{\frac{n}{2}}}{(2\pi)^{\frac{nd}{2}} |\hat{\Sigma}|^{\frac{n}{2}}} e^{-\frac{n}{2} \sum_{i=1}^d \lambda_i}.$$

Oppgave 3d

Med $\boldsymbol{\lambda} = (\lambda_1, \dots, \lambda_d)^t$ kan log-likelihoodfunksjonen nå skrives som

$$\mathcal{L}(\boldsymbol{\lambda}) = \frac{n}{2} \sum_{i=1}^d \ln \lambda_i - \frac{n}{2} \sum_{i=1}^d \lambda_i - \frac{nd}{2} \ln(2\pi) - \frac{n}{2} \ln |\hat{\Sigma}|,$$

slik at

$$\frac{\partial \mathcal{L}(\boldsymbol{\lambda})}{\partial \lambda_k} = \frac{n}{2\lambda_k} - \frac{n}{2} = 0 \quad \text{for } k = 1, \dots, d.$$

Dette gir løsningen

$$\underline{\underline{\lambda_1 = \lambda_2 = \dots = \lambda_d = 1.}}$$

Oppgave 3d (forts.)

Siden $\hat{\Sigma} = \Sigma A$, gir multiplikasjon med egenvektorene til A følgende

$$\hat{\Sigma} \mathbf{e}_k = \Sigma A \mathbf{e}_k, \quad k = 1, \dots, d$$

$$\Downarrow$$

$$\hat{\Sigma} \mathbf{e}_k = \Sigma \lambda_k \mathbf{e}_k, \quad k = 1, \dots, d$$

$$\Downarrow$$

$$\hat{\Sigma} \mathbf{e}_k = \Sigma \mathbf{e}_k, \quad (\text{siden } \lambda_k = 1)$$

$$\Downarrow$$

$$\hat{\Sigma} = \Sigma \quad (\text{siden alle } \mathbf{e}_k \neq 0)$$

Dette viser at $\hat{\Sigma}$ er maksimum-likelihoodløsningen for Σ , hvilket skulle bevises.

Oppgave 4

Likningssystemet for maksimum-likelihood (ML) estimatet av parametervektoren $\boldsymbol{\theta}$ i en gitt tetthetsfunksjon $p(\mathbf{x}|\boldsymbol{\theta})$ er

$$\sum_{k=1}^n \nabla_{\boldsymbol{\theta}} \ln p(\mathbf{x}_k | \boldsymbol{\theta}) = 0,$$

der \mathbf{x}_k , $k = 1, \dots, n$ er et sett av treningssampler.

Her skal vi finne ML-estimatet av parameteren μ i log-normalfordelingen

$$p(x|\mu) = \frac{1}{x\sigma\sqrt{2\pi}} e^{-\frac{(\ln x - \mu)^2}{2\sigma^2}}, \quad x > 0$$

der parameteren σ er kjent.

Oppgave 4 (forts.)

Innsetting i likningssystemet gir

$$\sum_{k=1}^n \nabla_{\mu} \ln p(x_k | \mu) = \sum_{k=1}^n \frac{d}{d\mu} \left\{ -\frac{(\ln x_k - \mu)^2}{2\sigma^2} - \ln(x_k \sigma \sqrt{2\pi}) \right\} = 0,$$

der gradienten i dette tilfellet reduseres til den deriverte med hensyn på parameteren μ . Dette gir likningen

$$\sum_{k=1}^n \left\{ -2 \frac{(\ln x_k - \mu)}{2\sigma^2} \right\} (-1) = 0,$$

som gir

$$\sum_{k=1}^n (\ln x_k - \mu) = 0, \text{ slik at } \sum_{k=1}^n \ln x_k = n\mu.$$

Parameterestimatet blir derved

$$\hat{\mu} = \frac{1}{n} \sum_{k=1}^n \ln x_k,$$

hvilket skulle vises.